

多模态大模型赋能的空天应急侦察智能 体 ：跨时相影像地理配准仿真与预算受限 主动重观测

作者（投稿前填写）

目录

1	引言	4
2	相关工作	6
3	系统架构与仿真平台	7
3.1	双模式智能体与有限动作集	7
3.2	地理配准仿真世界	9
3.3	人机协同控制台：平台实际能做的事	9
3.4	分层语义规划与记忆栈	10
4	方法与实验协议	13
4.1	预算受限主动重观测	13
4.2	视场收缩式观测模型	13
4.3	感知底座：公开披露的损伤分类组件	16
4.4	触发策略	17
4.5	事件不相交数据协议	17
4.6	运动学参数与预算换算	18

目录	2
4.7 评价指标与可识别性判据	18
5 实验	19
5.1 训练/验证曲线、类别加权与基线对标	20
5.2 旧观测模型：有效 GSD 与分类质量	21
5.3 旧观测模型：预算受限观测分配	24
5.4 视场收缩观测的几何落地与 leaky 感知诊断	26
5.5 功效分析与事件隔离基准	29
5.6 RescueNet 低空评估域	29
5.7 端到端缺陷与探索回退	30
5.8 Oracle 阶梯与端到端现实检验	31
6 局限与影响	34
7 结论	35
A 附录：协议、切分与复现	39

摘要

空天应急侦察的核心难题并非“能否让无人机听懂指令”，而是**第一次俯视的观测证据是否足以做出可信判断，若不足，何时值得再花航时去看一眼**。本文将后者表述为一个**预算受限的主动重观测**问题，并给出其物理自洽的观测模型与可检验的判据。

观测几何上，本文以固定传感器与固定视场角，把“下降”定义为连续底图上的**视场收缩**（巡航 1330 m、1.50 m/px 到下限 443 m、0.50 m/px），而非对同一裁块撤销人工模糊：地面足迹满足 $\text{footprint}(h) = 2h \tan(\theta/2)$ ，有效地面采样距离 $\text{GSD}(h) = \text{footprint}(h)/W$ 。该模型蕴含一个不变量——下限高度由“视场恰好覆盖一整张源瓦片”唯一确定为 443 m，此时有效分辨率**严格等于**源影像原生分辨率；因此信息上界由数据源原生 GSD 给出，任何进一步下降都无法恢复低于原生采样的结构（下采样信息损失的单向性）。题目锚定地理 ROI，答案与高度无关。

决策论上，动作集收窄为 {hold, descend_center}，以归一化熵 $U \in [0, 1]$ 量化观测不确定性，以条件期望熵减作为下降的预期收益；可识别性判据预先规定——若预测随 GSD 的翻转数不足，则任何预算分配策略在该数据上均**不可识别**，正确结论是“机制未被检验”而非“机制无效”（平均处理效应的可识别性要求处理能引起结果的非零变异）。

在此框架下得出三层结论。其一，损伤分级坍塌的根源经三方对照定位为**跨事件泛化**：同一冠军架构在事件不相交协议下重训的损伤 F1 仅 0.017，加载见过评测事件的现成权重为 0.630，约 97% 的差距来自事件曝光、约 3% 来自架构——即瓶颈是跨事件泛化，而非架构或训练规模。其二，在新观测模型与一个公开披露的强感知底座上，下降确实改变证据（逐建筑翻转 733、可纠正 375），但题目层面可纠正 13、破坏 10，效应被界定为**小且非单调**：机制从“不可测”推进为“可测但不可排序”。其三，重观测的机制作用在**置信标定而非定类**：160 题事件不相交基准上，重观测在 74/93 次中抬升置信度（均值 0.834 $\rightarrow$ 0.946），且置信度与正确率大致单调正相关（0.8 档 21.5%、0.9 档 41.8%、0.99 档 100%）。下降不改变“答什么”，但系统性地改变“多确定”——重观测的价值在于按置信度**可靠弃答**，而非提高准确率；置信度绝对值仍过度自信，故该价值幅度有限。

本文据此把“重观测何时值得”确立为一个**可检验的存在性问题**，而非“重观测必然改善成功率”的断言。本文贡献分两层：可运行的灾害智能体、物理自洽的仿真环境与预算受限主动重观测机制属于工程与机制存在性声明；可识别性优先评估、对负结果的反事实排除与瓶颈分解属于科学结论。前者不蕴含后者，尤其不蕴含重观测已经改善任务成功率。

1 引言

洪涝、地震与野火之后，指挥员更希望对无人机说“检查道路北侧那栋完全损毁建筑”，而不是给出精确坐标。执行这类指令需要语言条件目标搜索、导航与损伤评估，并且必须承认：第一次俯视图观测常常不够。鸟瞰条件下，小目标、配准误差、类别极不平衡以及卫星-航空域偏移都会使一次性置信判断不可靠。空天信息处理正从单平台、单模态感知向多模态大模型与智能体赋能的闭环演进：视觉语言大模型把自然语言指令、航拍/卫星影像与结构化感知统一到同一决策回路，智能体据此规划搜索、做出判断并决定是否需要主动复观测。

视觉语言导航(VLN)多在第一人称三维环境中研究 [1, 11]。灾害测绘则广泛使用地理配准的星载或航拍影像与灾前/灾后配对，如 xBD/xView2[9]。空中语言导航近期进一步引入分层语义规划与拓扑记忆 [17, 7, 15]。本文连接上述线索，构建一套多模态大模型赋能的空天应急侦察智能体，并在该系统上检验预算受限的主动重观测。验证出口刻意分层：把“校准不确定性能否转化为更好的观测分配”放在离线、无导航的预算实验中回答；把“现有栈在哪一层失败”放在 oracle 阶梯中诊断；把完整飞行闭环作为现实检验；把系统本身作为可运行、可复现的工程载体单独陈述（第3节），不把模块存在性写成任务增益。中心机制的形式化（动作集、归一化熵、期望熵减、共形触发）见 第4.1节。观测几何见 第4.2节：下降是视场收缩，不是撤销合成模糊。

本文的贡献归入三个主题：一个可运行、可复现的工程载体（系统、仿真与监控平台）；一个物理自洽的观测几何与预算受限的决策问题；以及一组对负结果的反事实排除与瓶颈分解。前两者是存在性声明，第三者是科学结论，三者之间不得互相推导。

本文贡献如下。

- **智能体系统与仿真/监控平台**（工程存在性声明）：双模式编排器（一次性任务规划与闭环语言导航）、分层语义规划与记忆栈、地理配准 xBD 俯视仿真，以及实时人机协同控制台。这些模块已实现并可复现（第3节）。该声明不蕴含导航成功率或重观测增益；尤其禁止把定位 Dice、提议召回或记忆图的存在写成判断/到达改善。

- **视场收缩式观测模型**：用固定传感器与固定视场角把高度写成可审计的有效 GSD；下限由“恰好一整张瓦片”反推为 443 m (0.50 m/px)，巡航为 1330 m (1.50 m/px)。题目锚定 ROI，答案不随高度改变。信息上界仍是源影像原生 GSD，不得解释为厘米级低空观测。
- **面向航空应急侦察的任务定义**：把校准不确定性转为预算受限的下降-居中动作，并以有效 GSD 作为物理可审计量。
- **离线观测分配实验**：在旧合成模糊阶梯、事件不相交裁块上比较校准/未校准/共形/oracle 参照，该构造下预测几乎不随 GSD 翻转、机制主张不可识别。在新视场收缩模型与一个已披露的强感知底座上，降高确实改变证据（逐建筑 $n_{\text{flip}} = 733$ 、 $n_{\text{correctable}} = 375$ ），但题目层面净收益为 MARGINAL——机制可测、效应小且不单调。
- **重观测的置信标定定位**：在 160 题事件不相交 Agent-VQA 基准上，重观测在 74/93 次中抬升置信度（均值 $0.834 \rightarrow 0.946$ ），且置信度与正确率大致单调正相关（0.8 档 21.5%、0.9 档 41.8%、0.99 档 100%）。下降不改变“答什么”、只改变“多确定”，据此把重观测的价值从“提高准确率”重新定位为“按置信度可靠弃答”，并量化其过度自信的幅度边界。
- **对该负结果的反事实排除与瓶颈分解**：训练/验证曲线核查排除“分类器从未训练成功”，类别加权重训排除“完全未处理类别不平衡”。一个三方对照把“架构/训练规模不足”与“事件曝光”两个竞争解释分离：同架构事件不相交重训后损伤 F1 仅 0.017，现成权重 0.630，差距约 97% 来自事件曝光——即损伤分级坍塌的根源是跨事件泛化，而非架构或裁块尺寸。
- **感知底座的角色**：xView2 冠军预训练权重（leaky，其训练划分见过评测事件）在本文中降级为公开披露的感知组件，仅提供真实损伤信号使智能体“有东西可感知”；本文不主张其跨事件泛化，也不把其绝对精度列为贡献。
- **泄漏安全协议与诊断**：事件级切分、功效分析、oracle 阶梯瓶颈归因（指认层，附命名修正）、以及 RescueNet 低空评估域。端到端历史全

零成功的三处实现缺陷排查记录在 第5.7节，作为可复现性说明而非独立科学贡献。

2 相关工作

航空应急侦察与鸟瞰导航。 无人机已被用于灾后快速测绘与建筑物损伤初判。AerialVLN 等将 VLN 扩展到空中平台 [11]，CityNav 则强调地理配准的城市鸟瞰导航 [10]。本文工作在地理配准的俯视仿真中进行，指令当前仍以损伤类别与方位约束为主，故正文采用“语言条件目标搜索”，避免对标室内 R2R 的过度框架。

分层语义规划与拓扑记忆。 CityNavAgent 用大语言模型把空中 VLN 拆成地标、目标与运动三层，并以全局拓扑记忆压缩长程动作空间 [17]。STMR 把俯视语义地图写成供语言模型阅读的数字网格，强调语义、拓扑与度量应同时进入提示 [7]。LM-Nav 则把语言模型抽地标、视觉语言模型对齐节点与图搜索沿熟路执行组合起来 [15]。本文借用这三条设计，适配到二维地理鸟瞰与有限动作集；实现细节见 第3.4节。这是架构借鉴，不是与上述系统的性能对标；端到端消融中打开记忆图并未改善严格成功率（第5.8节）。

遥感变化检测与 xBD 损伤评估。 xBD 提供灾前/灾后配对与四级 FEMA 风格损伤标签 [9]。后续变化检测工作（BIT、ChangeFormer、SNUNet 等）表明，显式建模时相差分有助于变化定位，但不自动带来校准良好的类概率 [5, 3, 6]。xView2 优胜方案通常把建筑定位与损伤分类分开，现成冠军权重至今仍是该基准上常用的参照上界。这些权重在官方按瓦片划分的 train+tier3 上训练，会见过本文按事件留出的测试/holdout 灾害，因此不能直接当作事件不相交主结果。本文采用双轨协议：现成权重只作 leaky 诊断上界，干净主结果要求同一架构在事件不相交协议下重训（第4.3节）。在线闭环默认仍使用自训练的双时相损伤头；RescueNet 提供与 xBD 四级损伤对齐的低空无人机分割标注 [13]，本文仅用作评估域。

主动感知与 Next-Best-View。 主动感知主张运动与传感联合选择 [2]。三维探索中的 receding-horizon next-best-view 规划是航空机器人的经典工

具 [4]。本文将动作集收窄为 {hold, descend_center}，以便在双时相分类器上把“再看一眼”做成可对照的预算分配问题。

校准、分布偏移与共形预测。 温度缩放是深度网络校准的标准后处理 [8]。分布偏移下校准往往先于精度崩溃 [12]。机器人规划中已有用共形预测决定“何时求助”的先例 (KnowNo) [14]。本文将共形集合大小作为与校准熵并列的触发器，强调覆盖保证而不是把信息增益过度声明为贝叶斯最优。

不确定性内省与具身智能。 具身智能需要知道何时观察不够。本文不把端到端成功率为零解释为“机制无效”：若上游从未产生损伤证据，重观测控制器根本没有被执行。这是实验设计问题，也是本文把机制研究从导航链解耦的原因。

MLLM 驱动的具身搜救基准。 与本文同期，ESARBench 把 MLLM 驱动的无人机具身智能体在搜救任务上标准化为基准：四个 UE5+AirSim、真实 GIS 重建场景、600 个搜救任务，指标为成功率/时间加权成功率/线索发现/救援分 [16]。其瓶颈诊断落在空间记忆与搜索效率-飞行安全权衡。本文与其互补而非重叠：ESARBench 测搜救导航与受害者定位，本文测损伤评估与预算受限重观测。

3 系统架构与仿真平台

本节描述已实现并可复现的智能体系统与仿真/监控平台。它是后续机制实验的运行载体，不是对导航成功率或重观测增益的度量声明；度量结论见 第5.2节-第5.8节。操作界面见图 1 与图 2-5；截图拍摄步骤见仓库 `paper_cja/SCREENSHOTS.md`。

3.1 双模式智能体与有限动作集

系统由事件驱动的服务端与响应式控制台构成，面向单架无人机、正射地理鸟瞰。编排器提供两种互补模式，动作空间显式、有限，不是开放的

工具调用循环：大语言模型只负责规划与指认，状态机在确定性执行器中闭合。

任务规划模式。 操作员在控制台输入一条自然语言任务（例如“飞到选点上空巡航高度悬停并做受灾检测”）。规划器调用语言模型，一次性输出固定模式的动作序列，字段为 `{action, params, reason}`；语言模型不可达时按关键词与经纬度规则回退。执行器按序调用同一套底层动作，并在控制台逐步回显计划与日志。

语言导航模式。 操作员输入目标描述（例如“飞到北侧寻找完全损毁的建筑”）。系统进入感知-决策-执行闭环：每步按当前经纬高渲染机载视场，运行检测/分割/双时相损伤分类，可选地由重观测控制器发出下降-居中，再由导航器输出相对位移、悬停或停止。导航器可切换为关键词贪心基线（套件 B0）或分层语义规划模块 HSPM（B1-B3 与 oracle 阶梯默认，见第3.4节）。

底层动作。 两种模式最终都落到同一组六类原子动作：飞到经纬高、相对位移、悬停、检测、标记与报告。语言导航另把停止作为回合终止符。重观测不是第 7 种独立动作枚举，而是在闭环内插入的相对位移（先水平居中、再按视场阶梯下降一档）。

感知栈。 机载观测由固定传感器边长 1024 px 与固定水平视场角 60° 决定地面足迹（第4.2节）。巡航高度 1330 m 对应 3×3 瓦片、1.50 m/px；下限 443 m 对应恰好一整张瓦片、0.50 m/px。渲染顺序为：Esri World Imagery 背景，叠加窗口内全部有地理配准的 xBD 灾后瓦片，色调协调后重采样到 1024^2 。灾前通道保持原生 GSD，不随高度降质；建筑提议在灾前整瓦片上以原生分辨率运行并按瓦片缓存，再把框仿射映射进当前视场，跨瓦片重叠以交并比 0.55 做非极大值抑制。在线闭环默认已切换为冠军方案检测后端（感知底座可分派）：灾前/灾后窗口喂双时相损伤分类，检测框按 ROI 过滤后再送下游。事件不相交训练的编码器-解码器定位网络与轻量双时相头保留为可回退的对照基线。同切分的单阶段检测器与场景分割、本地离线推理的开放词汇指认与灾情摘要仍作为并列模块。混合指认路径为检测

器类别命中优先、视觉语言模型兜底。禁止把定位 Dice 或提议召回写成导航或判断增益。

3.2 地理配准仿真世界

仿真世界把 xBD 灾后瓦片按地理足迹叠到 Esri 卫星底图上，像素-经纬度由瓦片仿射给出，原生地面采样距离 0.5 m/px。后端按当前视场窗口合成马赛克；控制台当前仍以激活瓦片为主显示，窗口内多瓦片叠加以及 FOV 足迹 / ROI 框的可视化尚未完成，不得把前端截图读成已经展示了“降高 = 收视场”。操作员可按灾害事件浏览瓦片目录、按损毁评分排序、一键激活瓦片并把无人机锚到瓦片中心；点选地图外位置时，系统会查找最近的 POST 覆盖并提示是否跳转，避免在无影像区域空飞。建筑多边形按 FEMA 四级着色，供操作员对照，**不作为智能体的作弊输入**。

运动学为二维匀速直线插值，不是六自由度飞控：水平速度 4–14 m/s（默认飞向地理点 14 m/s、相对位移 12 m/s），巡航高度 1330 m，高度下限 443 m，不含风扰、惯性、避障与电池消耗。视场随高度收缩，有效 GSD 由式 (4) 给出。数值预算与步长约定见 第4.6节。

3.3 人机协同控制台：平台实际能做的事

前端是实时监控/控制台，不是评测脚本的附属页面。操作员可以完成下列闭环，全部经事件通道推送世界状态、感知结果与思维链。

1. **选区与对照**。切换底图（卫星/街道）、叠加 xBD 灾后影像、显示或隐藏建筑足迹与瓦片边界；在真实地理坐标上看到无人机图标与飞行轨迹。
2. **手动飞行**。点地图飞向该点、悬停、标记兴趣点；左栏持续显示经纬高、航向、速度与锚点北东偏移。
3. **点选巡检**。在疑似受损建筑上发 Inspect：自动生成任务规划序列，飞到巡航高度悬停后跑 `detect_disaster`。底栏可在“机载视场 / 检测标注 / 场景分割”三页签间切换，并显示风险等级、受损/完好/车辆计数与可选的视觉语言模型摘要。

- 4. **语言目标搜索。**在 VLN 框下发一句话指令，无人机逐步感知并自主飞向目标；底栏显示当前技能、是否命中、距离、语义栅格统计（已探索格、地标、候选目标）以及重观测不确定性条。
- 5. **一次性任务规划。**在 AI Task 框下发复合任务，右侧列出逐步动作与理由，底栏日志同步执行过程，可随时 Stop。
- 6. **独立视觉问答。**控制台可上传任意图片调用同一套视觉语言模型做灾情分析，不依赖当前视场。

上述能力用于人机协同演示与单题排错；正文的成功率数字来自无界面的批处理评测脚本，二者不得混用账本。




图 1：系统分层：操作员经实时控制台驱动编排器，编排器调用语言模型、感知、规划与记忆模块，在地理配准仿真世界上执行有限动作集。

3.4 分层语义规划与记忆栈

语言导航闭环默认使用分层语义规划（HSPM），对照 B0 为关键词贪心基线。设计借鉴 CityNavAgent 的三层分解 [17]，适配到二维地理鸟瞰：地标层由语言模型把指令拆成有序子目标；目标层在当前子目标不可见时，把语义地图局部窗口交给语言模型做方位常识推理（OROI）；运动层把“可

待补截图 `paper_cja/figures/ui_overview.png`
拍摄步骤见 `paper_cja/SCREENSHOTS.md`

图 2: 控制台全貌: 顶栏模式切换, 左栏无人机位姿, 中栏地理配准态势图, 右栏任务规划与语言导航输入, 底栏感知与日志。

待补截图 `paper_cja/figures/map_overlay.png`
拍摄步骤见 `paper_cja/SCREENSHOTS.md`

图 3: 态势地图局部: 灾后卫星叠加、按损伤等级着色的建筑足迹、无人机图标与轨迹。建筑足迹仅供操作员对照, 不进入智能体观测。

待补截图 `paper_cja/figures/inspect_perception.png`
拍摄步骤见 `paper_cja/SCREENSHOTS.md`

图 4: 点选巡检后的感知三视图: 机载视场、检测框与场景分割; 右侧为风险摘要与可选视觉语言模型结论。



图 5: 语言导航进行中：地图轨迹、当前指令、技能与命中状态、语义栅格统计及重观测不确定性。

见则朝质心步进、不可见则按方位探索”写成一次相对位移，动作仍落在 {fly_relative, hover, stop}。本文不做与 CityNavAgent 的性能对标。

目标层不把俯视图直接交给视觉语言模型，而是把五层地理语义栅格（当前视场、已探索、地标、周边目标、候选目标）渲染为以无人机为中心的 数字网格、图例与目标方位摘要 (STMR) [7]。与原 STMR 的差异在于：本文已有真实地理参考，矩阵由二维语义地图直接切片，无需深度反投影。STMR 随 HSPM 一并启用，不是单独开关。

当语言模型或视觉语言模型不可达时，探索回退为螺旋搜索，禁止无方向先验时每步默认向北。判到达半径 (35 m) 大于成功半径 (25 m)，故判到达后先平移至目标估计位置正上方再停止。Oracle 指认与 oracle 初始定位用于阶梯诊断，不作为上线策略。

跨任务拓扑记忆把成功轨迹沉淀为节点（观测航点）与边（地表距离），下次相似指令先按文本匹配对齐地标、再用最短路沿熟路预飞 [15]。跨任务拓扑记忆默认关闭；端到端消融中仅 B3 打开。B3 在既有结果上并未提高严格成功率，导航误差反而变差（第 5.8 节），因此记忆图不得写成已验证的增益模块，只作为可开关的系统能力报告。

4 方法与实验协议

4.1 预算受限主动重观测

语言导航闭环给出候选建筑后，决策问题收窄为：当前观测的校准概率是否足以定类，若否，是否花一次额外航时去下降并居中。动作集为

$$\mathcal{A} = \{\text{hold}, \text{descend_center}\}. \quad (1)$$

hold 保持巡航高度继续使用当前视场；descend_center 先平移到目标估计位置正上方，再按视场跨度阶梯下降一档（默认两步从巡航到下限，单步 443 m），在更细的有效 GSD 上重跑损伤头。平均每样本允许 B 次额外下限档观测；每位置与每回合次数有硬上限（同一位置最多 2 次重观测）。

原理与直觉。该动作集把“再看一眼”收窄为一个二元决策：当前观测的校准概率是否足以定类，若否，是否值得付出一次下降的航时代价，换取更细有效 GSD 上的证据。动作集保持二元，是因为机制的**存在性**只需要一个可对照的“处理”（GSD 档位）与一个可测的“结果”（预测是否翻转）——这正是后文可识别性判据（第4.7节）得以成立的前提。

给定四类损伤的校准概率 $p_t \in \Delta^{K-1}$ ， $K = 4$ ，定义归一化熵

$$U_t = -\frac{1}{\log K} \sum_{k=1}^K p_{t,k} \log p_{t,k} \in [0, 1]. \quad (2)$$

下降动作的预期收益不是手调高度比，而是在验证观测上拟合的条件期望熵减

$$\widehat{\text{IG}}(a) = U_t - \widehat{\mathbb{E}}[U \mid \text{GSD}(a), \hat{y}_t], \quad (3)$$

其中 $\text{GSD}(a)$ 由视场-分辨率阶梯给出， $\hat{y}_t = \arg \max_k p_{t,k}$ 。 $\widehat{\text{IG}}$ 是查找表意义上的期望熵减，不是 Shannon 信息增益的无偏估计，不得写成贝叶斯最优。并列方法用分拆共形预测：当预测集合 $|C(x)| > 1$ 时认为证据不足以唯一定类，从而触发重观测，并报告 $1 - \alpha$ 覆盖。

4.2 视场收缩式观测模型

xBD 只有单一原生分辨率（0.5 m/px）。旧实现把巡航高度写成 30 m、下限写成 10 m，再对同一裁块做高斯模糊与升降采样；在该构造下，“下

降”等于逐步撤销我们自己加上的模糊，信息天花板由合成降质人为设定，且 10 m 飞行应对应厘米级 GSD，与 0.5 m/px 在物理上差两个数量级。当前系统改为固定传感器、固定视场角的几何模型：下降是在连续底图上收缩地面足迹，再重采样到固定输出像素，分辨率损失来自真实下采样比，而不是人工模糊。

设传感器输出边长 $W_{\text{px}} = 1024$ 、水平视场角 $\theta = 60^\circ$ ，则

$$\text{footprint}(h) = 2h \tan(\theta/2), \quad \text{GSD}(h) = \text{footprint}(h)/W_{\text{px}}. \quad (4)$$

xBD 瓦片为 1024×1024 像素、原生 0.5 m/px，地面跨度 512 m。约束“最小视场恰好等于一整张瓦片”唯一确定下限高度 $h_{\min} = 443.405 \text{ m}$ ，此时有效 GSD 严格等于原生 0.50 m/px；巡航取 3×3 瓦片跨度，得 $h_{\text{cruise}} = 1330.215 \text{ m}$ 、1.50 m/px。阶梯定义在瓦片跨度上 ($3.0 \rightarrow 2.0 \rightarrow 1.0$)，高度由式 (4) 反推，因此“下限 = 一整张瓦片”是不变量而不是需要维护的巧合（表1）。

原理与直觉。式 (4) 是正下视、平坦地面假设下针孔投影的退化形式：下降不改变成像几何，只按比例收缩地面足迹，因此有效分辨率随高度下降**单调上升**，直至触及源影像的原生采样上限。“下限 = 一整张瓦片”之所以是不变量，是因为它把最低观测高度处的有效分辨率**精确钉回**数据源的采样率，从而将信息上界从“人为设定的合成模糊”改写为“数据源的固有权值”。直觉上，下降如同把地面投影的传感器足迹像投影仪镜头逼近屏幕一样收缩——图像**不获得新内容**，只增加**每目标的像元数**。

边界与退化。上述几何依赖正下视与平坦地面。若地面存在起伏或传感器斜视， $\text{footprint}(h)$ 不再线性于 h ，有效 GSD 退化为随像元位置变化的**场**，“恰好一整张瓦片”的不变量随之失效，下降-居中的信息增益变为空间非均匀的。这正是该几何模型不能直接外推到真实低空斜视成像的原理层面原因（工程层面的风扰、运动模糊等见 第6节）。

443–1330 m 落在固定翼应急侦察 / 中空长航时平台的作业高度内，在该高度上 0.5 m/px 与传感器几何自洽。

该构造消除的是“下降 = 撤销合成模糊”与“把 0.5 m/px 写成 10 m 飞行”两处物理错误。它并不引入低于源影像的结构：仿真的信息上界仍是 xBD 的 0.5 m/px，低于该 GSD 的纹理不可恢复。后文凡引用旧合成阶梯

上的 $n_{\text{flip}} = 7$ 与预算分配零结果，只约束那一构造，不得改写成视场收缩模型已经提供了可识别的信息增益。

表 1: 视场收缩阶梯。高度由瓦片跨度与式 (4) 反推；ROI 边长比是中心标注瓦片在当前视场中的线性比例。

视图档	高度 (m)	GSD (m/px)	精度	macro-F1	Brier	NLL
巡航	1330.2	1.50	0.909	0.527	0.221	0.661
中间	886.8	1.00	0.911	0.553	0.218	0.658
下限	443.4	0.50	0.922	0.570	0.216	0.649

马赛克合成。 xBD 瓦片不是稠密网格，多数事件无法构成完整 3×3 真实覆盖。因此机载观测在地理窗口内先铺 Esri World Imagery ($z=18$ ，实测约 0.513 m/px) 作连续背景，再把窗口内全部有地理配准的 xBD 灾后瓦片按各自仿射叠上去，做逐通道均值/方差色调协调后重采样到 1024^2 。灾前时相走同一窗口，保证 pre/post 地理边界严格相同。纯黑 nodata 不计入 xBD 覆盖率，让底图透出。Esri 影像多为非事件当天（常为灾前）产品，在观测中仅作上下文背景：所有真值与所有问题作用域都限制在中心 ROI 的 xBD 标注上，背景不参与评分。底图来源与用途须保留 attribution；服务端批量缓存的条款合规性由作者复核，正文不把它写成已审定的许可结论。

ROI 作用域与场景池。 题目锚定中心那张有标注的灾后瓦片。答案与高度、与智能体动作无关，只由该 ROI 的 xBD 标注决定。巡航时 ROI 约占画面边长的 $1/3$ （面积 $1/9$ ），下降后逐步放大到铺满 1024^2 ，单位目标像素数来自真实源像素而非合成锐化。智能体通过题面与结构化观测字段获得 ROI 的地理四至；禁止在送给视觉语言模型的图像上画高亮框。方位类问题的真值相对 ROI 中心而非画面中心计算，否则居中动作会改写答案。为把源不连续限制在画面边缘，场景池只保留巡航窗口真实 xBD 覆盖率 ≥ 0.80 的瓦片 (495/4312)。合格场景偏向建成区密集、影像条带重叠多的区域；midwest-flooding 与 guatemala-volcano 完全退出 (表2)。这一选择偏倚必须写入场景定义，不得事后解释为“更有代表性的事件子集”。

表 2: 巡航覆盖率 ≥ 0.80 的 ROI 场景池 (495 个有地理配准的灾后瓦片)。

事件	合格 ROI 数
moore-tornado	160
hurricane-michael	89
socal-fire	65
nepal-flooding	58
hurricane-matthew	44
santa-rosa-wildfire	37
hurricane-harvey	12
hurricane-florence	10
mexico-earthquake	8
palu-tsunami	8
pinery-bushfire	4
合计	495

灾前通道保持原生分辨率。 灾前影像是地面站已归档的卫星产品，分辨率与无人机当前高度无关。若让 pre 随高度一起降质，则“降高”会同时恢复参考通道分辨率，相当于把旧的合成模糊错误搬到另一时相。实现上灾后视场恒为 1024^2 ，灾前窗口按 $\text{span}/0.5\text{ m}$ 渲染（巡航 3072^2 ），双时相裁块用 `pre_scale` 换算框坐标。

4.3 感知底座：公开披露的损伤分类组件

在线闭环的损伤分级由一个双时相分类头完成：共享编码器分别提取灾前/灾后特征，融合后接四类损伤头，验证集上拟合标量温度缩放。该组件在本论文中被明确降级为**公开披露的感知组件**，不列贡献，也不主张跨事件泛化。预训练权重在 xBD 官方划分上训练，而 xBD 按瓦片而非事件划分，本文的测试与留出事件全部被见过 (leaky)；正文的主动重观测机制研究默认运行在该底座上，结论只在该底座下成立。

损伤分级的历史瓶颈是类别坍缩：事件不相交训练的分类器对轻微/严重损伤召回为 0。为把坍缩的根源从架构中分离，做三方对照（同一切分、

同一评测)，**控制训练数据的“事件曝光”这一因子，固定架构这一因子**：事件不相交训练的轻量头、事件不相交重训的 xView2 冠军架构、以及加载见过评测事件的现成冠军权重。重训冠军架构的损伤 F1 仅 0.017，现成权重为 0.630——二者共享架构、仅在训练/评测事件是否重叠上不同，故差距约 97% 归因于事件曝光、约 3% 归因于架构。这直接回答了深度学习失效分析中常被混淆的问题——失效是**容量受限**还是**数据受限**：此处是后者。直觉上，分类器不是“看不见损伤”，而是“擅长识别它已经见过的事件”；坍缩是记忆/域偏移现象，而非容量天花板。该归因是单一架构族、单一协议下的点估计，且现成权重为 leaky 上界（见过评测事件），不作为跨事件泛化的证据。完整配方与逐类召回见 第5.1节，正文不把它写成独立的模型贡献。冠军方案输出语义分割而非实例，密集聚落中相邻轮廓会连成一片；评测对连通域做分水岭切分，超参只在训练事件上挑选。

4.4 触发策略

条件期望熵。 在验证观测上按 GSD 档与预测类统计平均熵，得到查找表 $\hat{\mathbb{E}}[U \mid \text{GSD}, \hat{y}]$ 。在线触发当 $\hat{\text{IG}}(\text{descend_center})$ 超过阈值且预算未耗尽。若表缺失则回退到高度比启发式，并在日志中标明。旧表在合成高斯模糊阶梯上拟合，schema 与视场收缩阶梯不兼容，加载器会拒绝并回退启发式；新阶梯的离线拟合尚未完成，因此当前闭环不得把条件期望熵写成已在新几何上生效。

共形集合。 在验证集上用 Adaptive Prediction Sets 拟合分位数 $\hat{q}_{1-\alpha}$ 。预测集合取累积概率达到 $\hat{q}$ 的最小标签子集；当 $|C(x)| > 1$ 时触发下降。

对照包括：永不下降、随机花预算、未校准峰值/熵阈值、固定下降。零触发回合对条件熵差视为缺失，触发率报 0，不得填补成功下降。

4.5 事件不相交数据协议

灾害事件而非作物块是划分单位。训练、温度拟合（验证）、测试与留出使用互斥事件集合，见附录。任一评测题的 `disaster` 落入训练或验证集合即视为泄漏并在生成脚本中断言失败。题库审核字段记录为“模型辅助

审核 + 作者抽查”，不得写成纯人工审核。轨 A 权重见过测试/留出事件，不满足本节协议；凡使用轨 A 的评测必须在产物里写 `leaky=true`，并不得与干净切分的主结果并列解读。旧观测模型下的留出评测已经一次性消费，只能作为该系统的历史记录。视场收缩与感知底座更换构成新系统，其预注册（配置冻结、指标判据、留出事件）与 pilot/留出评测已按新协议执行：留出事件与 pilot 事件互斥，结果一次性消费，不得回写调参。

4.6 运动学参数与预算换算

语言导航默认步数预算 12，判到达半径 35 m，成功半径 25 m，朝目标单步上限 80 m，未命中时探索步长 90 m。重观测按视场阶梯下降，单步 443.405 m，同一位置最多 2 次（两步从巡航到下限），水平居中位移上限 40 m。仿真器为实时演示把单段飞行时长封顶为 8 s，因此墙钟时间不能当作航时；按距离/速度换算、忽略该封顶：探索步 90 m 约 7.5 s，12 步巡航约 90 s；一次下降 443 m（复核速度 10 m/s）约 44 s，两次下降共约 89 s，一次 40 m 居中约 3.3 s。相对旧的 30 → 10 m 标定，垂直机动从巡航预算的数个百分点变成与 12 步巡航同量级的航时。离线实验中平均每样本额外观测预算 $B = 0.25$ 对应每四个观测一次下降-居中；该换算只给出数量级，不能外推到真实续航，也不得继续沿用旧文“数个百分点等效航时”的表述。

4.7 评价指标与可识别性判据

端到端到达指标如下，首次出现即给出定义，后文用缩写。**严格成功率 SR**：回合终止时无人机与目标的水平距离 ≤ 25 m 的比例。**语义成功率 semSR**：在指令所述损伤类别的真值建筑集合上，距离最近真值 ≤ 25 m 的比例；它宽于 SR，不得写成严格成功。**导航误差 NE**：终止位置到目标的水平距离（米），报告均值。**路径效率 SPL**：成功回合按最短路径与实际路径长度比加权，失败回合记 0，再对题平均。

离线判断指标为总体精度、宏观 F1、ECE，以及预测翻转次数

$$n_{\text{flip}} = \#\{i : \hat{y}_i^{\text{cruise}} \neq \hat{y}_i^{\text{native}}\}. \quad (5)$$

在 ROI-scoped 设定下，巡航档与下限档比较的是同一 ROI 上的定类，而不是视场扩大后换了一道题。**可识别性判据（预先写死，而非为负结果事**

后找解释)。“下降是否改善决策质量”本质上是一个**平均处理效应**：处理为 GSD 档位，结果为预测类。一个处理效应可识别，当且仅当处理能引起结果的非零变异——在本设定中即翻转数 n_{flip} 非零。若 n_{flip} 过小，或校准策略与不下降、随机之间的宏观 F1 差距（相对逐样本翻转参照）含 0，则任何预算分配策略在该数据上都**不可识别**：正确结论是“机制未得到检验”，而非“机制无效于导航”。这是“无变异则无实验”这一因果推断基本原理在观测分配问题上的直接对应。逐样本翻转知识的贪心分配是宏观 F1 的参照而不是上界：宏观 F1 对样本不可加，策略曲线超过该参照并不构成逻辑矛盾，后文改称“oracle 参照”。

旧合成阶梯上已测得 $n_{\text{flip}} = 7$ ($n = 400$)，机制不可识别。新观测模型与公开披露底座上的前置检查（48 个 ROI、7695 栋建筑）测得逐建筑 $n_{\text{flip}} = 733$ 、 $n_{\text{correctable}} = 375$ ，但题目层面 $n_{\text{correctable}} = 13$ 、 $n_{\text{harmful}} = 10$ ——降高确实改变证据，但翻转有得有失。结合功效分析（第5.5节），题目层面观察到的效应低于最小可检测效应，故正确结论是“**效应被界定为小且非单调**”（有界小效应），而非“效应为零”：这是“absence of evidence 不等于 evidence of absence”的严格表述。该判定预先写死：若题目层面可纠正样本仍为个位数，E4 只能报告不可识别，不得因更换几何或检测器改写可识别性口径，也不得预设主动重观测会从不可识别转为可识别。

5 实验

实验按自下而上顺序报告：先分类器能力核查，再旧观测模型上的有效 GSD 与观测分配，再新几何的落地验证与 leaky 感知诊断，再功效与基准，最后 oracle 阶梯与端到端现实检验。不把定位提升写成导航贡献，也不把 semSR 当作严格成功。评价指标与可识别性判据见 第4.7节。

两套观测模型不得混账。 第5.1节–第5.3节与 第5.8节的数字全部在旧观测模型上获得：巡航 30 m、下限 10 m、对同一裁块做合成高斯模糊，分类裁块约 96×96 。它们作为该构造上的历史记录保留，并用于反事实排除。第5.4节报告视场收缩模型的几何落地、三方检测器对照与可识别性前置检查，以及新底座上的 Agent-VQA pilot。旧 Agent-VQA 留出（分支 C）同

属旧系统，不能充当新系统的验证集。

5.1 训练/验证曲线、类别加权与基线对标

此前从未报告损伤分类器在训练/验证集上的逐类表现，因此“损伤头先失败”这一归因无法与“训练本身失败（数据/标签 bug）”区分。我们据此补做三组对照实验，结果汇总于表3与表4。

训练曲线：确有信号，但不跨事件泛化。 按第4节的类别加权 + macro-F1 选择重训后，训练集 macro-F1 随训练轮次从 0.22 单调升至 0.49–0.57（表4），说明分类器确实学到了区分损伤等级的视觉线索，排除“从未训练成功”这一竞争解释。但验证集（hurricane-harvey、mexico-earthquake，与训练事件不相交）macro-F1 全程停留在 0.21–0.25，不随训练集拟合程度提升而改善，验证损失反而缓慢上升（过拟合）。这是一条干净的“训练内有信号、跨事件不泛化”曲线，构成事件级域偏移的直接证据，而不是训练流程 bug 的证据。

类别加权部分缓解塌缩，但未逆转。 表3 对比未加权（论文早期版本）与类别加权（当前版本）模型快照：测试集 macro-F1 从 0.220 升至 0.276，“损毁”类召回从 0.007 恢复到 0.164；但“轻微损伤”与“严重损伤”召回仍接近 0。加权训练有效但不充分，核心瓶颈判断不变。

与标准（非事件不相交）切分对照，拆分协议难度与架构差距。 本文刻意使用比公开 xBD 基线更严格的事件级切分（不同灾害事件，见第5.1节前言），但由此产生的 macro-F1 ≈ 0.7 （文献常见数值）与本文 ≈ 0.28 之间的差距，可能来自 (i) 评测协议更难，也可能来自 (ii) 本文架构/训练配方偏简单（轻量双塔编码器、有限训练轮次、无集成）。我们用同一架构在**官方标准切分**（图像级随机切分，训练/测试可共享灾害事件，与文献协议一致）上重训一次以分离两个因素：测试集 macro-F1 升至 0.308（表3 末行）——比事件不相交高约 0.03–0.04，但仍远低于文献的 ~ 0.7 。据此，协议难度只能解释差距的一小部分（ $\lesssim 0.04$ ）。剩余差距的归因由第5.4节的三方对照给出：同一 SOTA 架构事件不相交重训（轨 B）的损伤 F1 仅 0.017，与加载

见过评测事件的现成权重 0.630 差距约 97% 来自事件曝光——即架构/训练规模不是充分解释，跨事件泛化才是瓶颈。直接借用公开预训练权重会因其训练集覆盖本文全部 val/test/holdout 事件而构成泄漏（见 第2节、附录）。

H2: 差分注意力与拼接融合无统计显著差异。 表3 第 2、3 行对比同一事件不相交切分下的两种融合方式：拼接在验证集选择指标上略高（macro-F1 0.241 vs. 0.222），差分注意力在测试集“损毁”召回上明显更高（0.164 vs. 0.055），两者互有胜负，样本量下不足以判定何者更优。H2 的结论是“在本数据规模下无法区分”，而非任一方向的优势。

表 3: 新旧模型快照、两种融合架构与两种切分协议的 macro-F1 / 逐类召回对照。

checkpoint	train F1	val F1	test F1	test 完好召回	test 损毁召回	切分协议
旧（未加权，论文原用）	0.242	0.221	0.220	0.989	0.007	事件不相交
v2 差分注意力（加权）	0.348	0.222	0.276	0.973	0.164	事件不相交
v2 拼接（加权，H2 对照）	0.370	0.241	0.265	0.951	0.055	事件不相交
标准切分拼接（加权，协议对照）	0.330	0.350	0.308	0.995	0.233	标准（非事件不相交）

5.2 旧观测模型：有效 GSD 与分类质量

表5 给出重训后（类别加权、差分注意力）模型快照在旧合成模糊阶梯上、巡航档到原生档的精度、macro-F1 与 ECE ($n = 400$ ，事件不相交测试集)。原生档预测为“完好”381、“损毁”19，巡航-原生预测翻转 7 次（表6）。配对 bootstrap 下原生档相对巡航档的精度差均值为 -0.0025 ，95% 置信区间 $[-0.0125, 0.0075]$ 含 0，验收仍为 `accept_native_better=false`。macro-F1 在五档间为 0.273–0.286，较未加权版本的 0.184 平坦值有提升但仍以完好类为主。

为排除“4× 降质过弱”，另将尺度加到 8× 与 16×（有效 GSD 4m 与 8m）：预测分布与翻转次数无实质变化（单元测试确认降质本身会改变高频像素，因此不是空操作）。当前损伤头对纹理的敏感度不足以支撑跨 GSD 的信息增益估计，但方向已不再反常——见图 6。这些测量描述的是合成模糊阶梯，不是视场收缩阶梯。

表 4: 类别加权训练下的逐训练轮次 train/val macro-F1 (训练内有信号、验证集不改善)。

配置	epoch	train macro-F1	val macro-F1	train acc	val acc
差分注意力 (事件不相交, 加权)	1	0.220	0.222	0.735	0.797
	2	0.275	0.208	0.735	0.673
	3	0.336	0.224	0.757	0.755
	4	0.376	0.224	0.787	0.754
	5	0.400	0.216	0.796	0.720
	6	0.414	0.215	0.798	0.719
	7	0.438	0.220	0.804	0.745
	8	0.486	0.223	0.804	0.786
拼接 (事件不相交, 加权)	1	0.242	0.232	0.729	0.788
	2	0.294	0.219	0.733	0.704
	3	0.325	0.213	0.737	0.683
	4	0.411	0.247	0.784	0.783
	5	0.449	0.208	0.807	0.675
	6	0.498	0.225	0.814	0.782
	7	0.541	0.220	0.819	0.774
	8	0.568	0.224	0.824	0.779
拼接 (官方标准切分, 加权)	1	0.219	0.213	0.755	0.741
	2	0.266	0.310	0.748	0.740
	3	0.313	0.213	0.749	0.741
	4	0.395	0.318	0.777	0.760
	5	0.451	0.294	0.793	0.753
	6	0.481	0.344	0.795	0.767
	7	0.519	0.333	0.800	0.761
	8	0.559	0.325	0.806	0.765

表 5: 旧观测模型（合成模糊阶梯）上的高度-GSD 测量 ($n = 400$, 类别加权模型快照)。该表不描述视场收缩模型。

尺度 / 有效 GSD	精度	macro-F1	ECE	平均熵
1.00× / 0.50 m	0.623	0.286	0.042	0.776
1.75× / 0.88 m	0.623	0.286	0.055	0.776
2.50× / 1.25 m	0.620	0.273	0.053	0.777
3.25× / 1.62 m	0.623	0.279	0.049	0.779
4.00× / 2.00 m	0.625	0.279	0.086	0.782

表 6: 同一测试裁块上的类别支持数、原生档预测数与召回。巡航-原生预测翻转 7 次。

类别	标注数	原生档预测数	原生档召回
完好	250	381	0.972
轻微损伤	125	0	0.000
严重损伤	12	0	0.000
损毁	13	19	0.462
巡航 ↔ 原生预测翻转			7




图 6: 旧合成阶梯上有效 GSD 与 macro-F1 / ECE。macro-F1 大致平坦；平均熵随 GSD 变粗**单调上升**——方向与“下降应降低不确定性”的假设一致（未加权版本曾观察到方向相反，见附录变更记录），但幅度很小，仍不足以支撑稳健的跨 GSD 触发决策。

5.3 旧观测模型：预算受限观测分配

设定：每样本平均允许 $B \in \{0, 0.1, 0.25, 0.5, 1.0\}$ 次原生档观测。策略为不下降、随机、未校准熵、校准熵、条件期望熵、共形集合以及已知标签是否翻转的 oracle。类别加权模型快照重跑后，400 个配对样本中巡航预测与原生预测相差 7 例 ($n_{\text{flip}} = 7$ ，较未加权版本的 1 例增加，但绝对量仍很小)。表 7 中各策略在 $B = 0.25$ 时 macro-F1 集中在 0.277–0.286，oracle 参照与不下降之间的差距仅 0.0094，`accept_calibrated_better=false` 依旧成立。可分配信息量随分类器改善而略有增加 (n_{flip} 从 1 到 7)，但幅度仍不足以让任何触发策略在宏观 F1 上跑赢随机或不下降。表中 ECE 出现约两倍分离（不下降 0.086，未校准/校准熵约 0.038）：这与温度缩放不改变 $\arg \max$ 相符，说明机制作用在概率而非标签；宏观 F1 平坦不能单独写成“校准无用”。这与第 5.1 节的判断一致：分类器改善方向正确，但在旧构造与当前分类器规模下，下降-居中动作尚未产生可辨识的**定类**收益。

超参 $\tau \in \{0.3, 0.4, 0.5, 0.6, 0.7\}$ 只改变下降次数，macro-F1 基本不变，敏感性分析在当前分类器规模下仍缺乏信息量。

表 7: 旧观测模型上, 平均每样本额外观测 $B = 0.25$ 时的损伤判定 ($n = 400$, 类别加权模型快照, $n_{\text{flip}} = 7$)。末行是逐样本翻转参照, 不是宏观 F1 上界。

策略	macro-F1	精度	ECE	Brier	NLL	净纠正
不下降	0.612	0.725	0.242	0.481	1.356	0
随机	0.624	0.730	0.244	0.475	1.336	19
未校准熵	0.645	0.740	0.258	0.475	1.373	55
校准熵	0.643	0.739	0.261	0.476	1.377	53
条件期望熵	0.631	0.736	0.255	0.477	1.369	40
Conformal	0.637	0.734	0.255	0.476	1.374	35
Oracle 上界	0.693	0.776	0.285	0.462	1.309	191




图 7: 额外观测预算与损伤宏观 F1 (旧合成阶梯)。各策略曲线高度重叠; oracle 曲线是逐样本翻转参照而非宏观 F1 上界。

5.4 视场收缩观测的几何落地与 leaky 感知诊断

本节只报告已经完成、可复核的落地结果，不把它们写成新系统的任务增益。

几何不变量。 单元测试锁定：下限高度 443.405 m 渲染出恰好 1.000 张瓦片、有效 GSD 恰好 0.500000 m/px；巡航 1330.215 m 对应 3.0 张瓦片、1.50 m/px。pre/post 使用严格相同的地理窗口；ROI 覆盖不足时显式失败；nodata 不计入 xBD 覆盖率。当前 ROI 索引覆盖 4312 个有地理配准的灾后瓦片，其中巡航覆盖率 ≥ 0.80 的为 495 个（表2）。

三档端到端样例。 在 hurricane-michael_00000034 上，默认马赛克路径生成三档观测（表8）。检测数可由对应 p2b_*_det.json 复核。建筑密度跨三档大致一致（约 209–278/km²），与“降高收缩视场、提高 ROI 单位像素数”的几何行为相符。闭环单步延迟约 8.3 s，高于预先设定的 2 s 门槛；瓶颈在预分辨率渲染与逐目标双时相推理的未批量化。ROI 内筛选已落地（检测框只保留中心落在 ROI 内的部分，密集瓦片由数千框降到数十框），但预分辨率渲染与批处理仍未优化。

表 8: 视场收缩模型的三档端到端样例 (hurricane-michael_00000034, 在线对照检测器)。检测数来自产物记录；覆盖率、pre_scale 与耗时来自执行记录。GSD 单位为 m/px，耗时为秒。

档位	有效 GSD (m/px)	pre_scale	检测数	xBD 覆盖率	暖缓存耗时 (s)
巡航 (1330m)	1.50	3.0	657	0.988	8.3
中档 (887m)	1.00	2.0	219	1.000	3.9
下限 (443m)	0.50	1.0	63	1.000	1.8

三方检测器对照：损伤分级坍塌的根源是跨事件泛化。 在事件不相交测试事件 (hurricane-michael + palu-tsunami, 30 张瓦片) 上对照三个感知底座（表9）：自训练轻量头、事件不相交重训的 xView2 冠军架构、以及加载见过评测事件的现成冠军权重。定位能力三者接近 (loc F1 0.807 / 0.832 / 0.853)，差距几乎全部在损伤分级：前两者对轻微/严重损伤召回接近 0

(损伤 F1 0.000 / 0.017), 现成权重为 0.630。同一架构、同一评测, 只有数据协议不同——差距约 97% 来自事件曝光、约 3% 来自架构。这直接回答了“剩余差距是否来自架构”: 跨事件泛化是瓶颈, 架构与裁块尺寸不是充分解释。现成权重因此只作公开披露的感知底座 (leaky), 不进入正式对照主表; 单模型 overall 0.697 略低于 0.7 门槛, 与文献 0.803 的官方混合划分口径不同, 不作对标。

表 9: 检测器离线对照 (测试事件 30 张瓦片)。标记 [†] 的两列必须读作 leaky 诊断上界, 不得进入正式对照主表, 也不得与自训练基线的差值单独归因于架构。damage F1 为四类调和平均。

后端	loc F1	damage F1	轻微召回	严重召回	损毁召回	事件曝光
自训练轻量头 (事件不相交)	0.807	0.000	0.000	0.000	0.000	否
冠军架构重训 (事件不相交)	0.832	0.017	0.020	0.014	0.081	否
冠军现成权重 [†]	0.853	0.630	0.557	0.407	0.199	是

可识别性前置检查与 Agent-VQA pilot。 新观测模型与 leaky 底座上的前置检查 (48 个 ROI、7695 栋建筑) 测得逐建筑 $n_{\text{flip}} = 733$ 、 $n_{\text{correctable}} = 375$, 但题目层面 $n_{\text{correctable}} = 13$ 、 $n_{\text{harmful}} = 10$ ——降高确实改变证据, 但翻转有得有失, 判定为 MARGINAL。

Agent-VQA pilot (test split, 40 题) 确认动作通道接通: 固定下降每问触发 2 次 (共 78 次), 熵触发 11 次、跳过 33 次。最终准确率上重观测策略 (0.30) 较不重观测的搜索基线 (0.25) 高 5 个百分点, 但只是 2 道题, $n = 40$ 下不显著, 且固定下降纠正 4 题、破坏 2 题。结论落在预注册的分支 C: 机制可识别、效应小且不单调, 不足以排序候选策略。

留出事件复现。 留出事件 (moore-tornado + nepal-flooding, 40 题, 与 pilot 事件互斥) 上重复同一套配置: 不重观测的搜索基线准确率 0.425, 固定下降 0.45 (每问触发 2 次、共 79 次, 纠正 4 题、破坏 2 题), 熵触发 0.40 (仅触发 3 次、跳过 38 次, 无纠正)。与 pilot 一致: 效应约 1 题、不单调, 且事件间方差 (moore-tornado 0.60 vs. nepal-flooding 0.25) 远大于任何策略差。两条互斥事件上的证据共同锁定分支 C: 机制可识别、效应小、不可排序候选策略。

全量基准与置信标定定位。 把 pilot 与留出事件合并为 160 题事件不相交基准后，重观测的**定类**效应依旧不可辨识：单观测基线准确率 0.3125，各重观测策略（随机/固定/校准熵/条件期望熵/共形）落在 0.30–0.32，与基线配对 McNemar $p = 1.0$ ；事后 oracle 参照仅 0.3187（较基线 +0.6%，160 题中仅 1 题可纠正、2 题可破坏、109 题两者皆错）。但机制在**置信通道**上可测：93 次重观测中 74 次抬升置信度（均值 $0.834 \rightarrow 0.946$ ）、18 次持平、1 次下降；置信度与正确率大致单调正相关（0.8 档 21.5%、0.9 档 41.8%、0.99 档 100%，表10）；但 0.99 档几乎全为“无损伤”负例确认（53/54），重观测后的中间档 0.95 仅 30.8%（ $n = 13$ ）非单调回落。据此把重观测的价值定位从“提高准确率”修正为“按置信度可靠弃答”：下降不改变答案，却把“低置信误答”推向可被阈值识别的高置信区间。注意置信度绝对值仍过度自信（0.9 档实际正确率仅 41.8%），故该价值可兑现的幅度有限，不构成“重观测改善成功率”的证据。

表 10: 重观测的置信标定（160 题事件不相交基准）。置信度与正确率大致单调正相关；重观测在 93 次中 74 次抬升置信度（均值 $0.834 \rightarrow 0.946$ ）。高置信尾（ $\text{conf} \geq 0.9$ ）上共形重观测（A4）正确率高于单观测（A0）。

分组	作答数	正确率
置信度 0.80	918	21.5%
置信度 0.90	572	41.8%
置信度 0.95	13	30.8%
置信度 0.99	54	100.0%
$\text{conf} \geq 0.9$ 单观测 (A0)	62	43.5%
$\text{conf} \geq 0.9$ 共形重观测 (A4)	65	52.3%

仍未完成的检查。 (i) 只看合成图能否预测 ROI 或影像来源的泄漏体检尚未运行，不能声称 Esri 与 xBD 的源差异已被实验排除；(ii) 熵表尚未按新阶梯重拟合，条件期望熵策略当前回退到高度比启发式。这两项不影响本文结论，但限制对触发策略内部机制的强声明。

5.5 功效分析与事件隔离基准

旧设计 40 题 $\times$ 3 种子、6 策略 Holm 校正下，最小可检测严格 SR 差值约为 9.6 个百分点（基线 SR=0.05、功效 0.8），远大于 plausible 的 2-5 个百分点效应，故“本次不显著”在设计上接近“永不显著”。功效 0.8 检测 5 个百分点增益约需每策略 444 题。新基准为 200 题，仍欠功效约 2.2 倍，故后文端到端各策略 SR 同质应读作**欠功效下的非结果**，而不是已经证伪了 2-5 个百分点的效应。新 evidence-rich 草稿仅含 test+holdout 事件 (hurricane-michael、palu-tsunami、moore-tornado、nepal-flooding、pinery-bushfire)，200 题中 easy/medium/hard 为 75/70/55，含 33 条多地标；审核字段为“模型辅助审核 + 作者抽查”，生成脚本对 train/val 事件断言失败。该题库仍为 schema agent-vqa/1.1，起始位姿与空间真值仍相对旧巡航半径，不能代替计划中的 ROI-scoped v2.0 题库。在新几何上的可识别性前置检查通过之前，扩大题库不能单独挽救观测分配实验。

表 11: 六策略 Holm 校正下的样本量规划。表中 0.0962 是相对基线 SR 的最小可检测差值，不是成功率本身。

量	取值
基线 SR	0.05
目标绝对增益	0.05
Holm α	0.01
功效 0.8 所需每策略题数	444
旧设计最小可检测 SR	0.0962

5.6 RescueNet 低空评估域

RescueNet 为 Hurricane Michael 无人机影像，建筑损伤按 FEMA 四级标注，与 xBD 四类直接映射 [13]；数据来自 Scientific Data/figshare 的 CC BY 4.0 发布，仅评估、不训练。该数据集无灾前配对，双时相输入将灾后裁块复制为灾前通道（差通道**恒为** 0，不是近似为 0）。这一输入构造本身就保证“无变化 $\rightarrow$ 完好”是数学必然，而不是域漂移的独立证据：本节结果因此只度量卫星训练分类器在真实低空外观上的漂移，不能作为“绑

定约束在损伤头而非卫星 GSD” 的独立支持证据；后者需要单时相（仅灾后）分类头对照，本文暂未实现，留作后续工作。FloodNet 因只有淹没/未淹没二值标签且与四级损伤不对齐，不引入。类别加权模型快照重跑结果与塌缩模式一致：完好类召回为 1.00，三类损伤召回均为 0；精度 0.210、macro-F1 0.087、ECE 0.421（表12）。

表 12: 卫星训练分类器在 RescueNet 测试影像上的零样本漂移（灾后裁块复制为灾前）。

项	支持数	指标
图像数	80	—
建筑连通域	181	—
精度	—	0.210
macro-F1	—	0.087
ECE	—	0.421
完好召回	38	1.000
轻微损伤召回	41	0.000
严重损伤召回	22	0.000
损毁召回	80	0.000

5.7 端到端缺陷与探索回退

对历史全零结果的排查结论如下。

1. 旧题库首题起点-目标距离 48.19 m，北向 -20.8 m、东向 43.5 m，不符合 lat/lon 互换的几何签名。
2. E1 与 E11 使用同一 evidence-rich 题库；在重观测从未触发时，B1-B3 与六策略轨迹级聚合相同是预期现象，不是串台。
3. LLM/VLM 不可达时，分层规划对无方向先验题每步默认向北， 12×90 m 量级位移与平均 NE 587.6 m 相符。已改为螺旋搜索，单测验证连续四步不再恒为北。

4. **零提议根因（第二处独立缺陷）**：编码器-解码器定位网络推理时把任意输入缩放到训练尺寸，256 px 机载视场被上采样后建筑尺度偏离训练分布，提议塌缩为 0——同一权重在完整 1024 px 瓦片上产生 95 个提议，在 256 视场上为 0。修复为：对灾前底图整瓦片做一次原生分辨率定位（进程内缓存），再把落进当前视场的框平移到视场坐标；且灾前底图是离线卫星产品，其分辨率与无人机当前高度无关，不再随观测阶梯降质，只有灾后实时观测随视场重采样。修复后单题 trace 每步产生 2-10 个建筑提议、损伤分类器全部被调用（此前全程为 0），证据链路首次完整执行。
5. 修复后损伤证据以“完好”为主：分类器对少数“损毁”案例已有一定命中（第5.1节），但“轻微/严重损伤”证据仍几乎不出现，与第5.2节的离线结论闭环——瓶颈不在导航或定位，在损伤头对中间损伤等级的召回。
6. **VLM 恢复与混合指认验证**：视觉语言模型改为本地离线推理直接加载（本地权重、离线可复现，不依赖外部推理服务），混合指认路径（检测器优先、视觉语言模型兜底）真实生效。
7. **早停缺陷（第三处独立缺陷）**：两个规划器在目标进入判到达半径（35 m）后原地停止而不平移到目标上方，而成功半径为 25 m，构成系统性早停。修复为判到达后先对准目标再停止。
8. 修复后单题 trace 暴露新的真实误差源：VLM 在起点视场内指认了一处“完全损毁建筑”（视场内 19 m），但对齐 GT 足迹后该位置 61 m 内无损毁建筑，属开放词汇指认误报。这类误报不是实现缺陷，而是需要重观测机制去纠偏的对象——但重观测又受损伤头塌缩约束，两个失效源在端到端层面耦合。

5.8 Oracle 阶梯与端到端现实检验

在全部修复后的栈上，于事件隔离基准（200 题）重跑：(i) oracle 阶梯 L0-L3（表13），交叉解耦导航与指认；(ii) 主消融 B0-B3 与重观测策略族、GPS 定位扰动（ $\sigma \in \{2, 5, 10\}$ m）及强制退化几何套件（表14）。解释时须

注意：这些数字属于旧观测模型与旧题库；在损伤头塌缩的前提下，任何配置的损伤证据与重观测触发都受同一上游约束。

L2 是 oracle 初始定位，不是 oracle 导航。 L2 的实现是回合开始即把无人机放到目标正上方，指认模块此后仍照常运行、仍可将其重新拉离目标——导航/运动闭环本身从未被替换或屏蔽。因此 L1–L2 的差值度量的是“指认 vs. 初始位置”，不是“指认 vs. 导航”，下文改称 L2 为“oracle 初始定位”，避免层间归因被误读为对导航模块的检验。真正的 oracle 导航（屏蔽指认对运动的影响）留作后续工作。

瓶颈定位在指认层。 oracle 阶梯给出层间归因：仅替换指认（L1）即把严格 SR 从 0.08 提升到 1.00（NE 0.1 m、SPL 0.986），说明指认正确时规划–运动闭环几乎无损；而仅替换初始定位（L2）——不屏蔽指认——SR 只有 0.50：一半的题在到达后仍被开放词汇误指认重新拉离目标。两者对比表明目标指认是当前剩余瓶颈的主要来源：检测器路径受限于损伤头对中间损伤等级的低召回，VLM 路径则存在 第5.7节所示的开放词汇误报，二者叠加构成 L0 的低 SR。这一结论的边界条件须明确：仿真不含风扰、避障与能耗约束，SR = 1.00 说明“指认正确时该仿真的运动学假设下闭环无损”，不能外推为“导航与运动闭环对真实飞行不再是短板”。

端到端上机制不可辨识，与离线分水岭闭环。 主消融 B0–B2 的 SR 在 0.07–0.08 之间同质，记忆拓扑图（B3）反而使 NE 变差（305.7 m）。五种重观测策略（随机、固定、校准熵、条件期望熵、conformal）SR 完全相同（0.08），200 题中触发 0–3 次：损伤证据几乎不存在时，任何触发准则都退化为“从不触发”。这与 第5.3节的离线结论在端到端层面闭环——不是重观测机制失败，而是它从未获得可复核的输入。新观测模型与 leaky 底座上，前置检查测得逐建筑翻转 733，但题目层面效应小且不单调（第5.4节）：局面从“不可测”部分推进为“可测但不可排序”，机制层面的结论不变。

几何扰动不是当前瓶颈；强制退化几何下 SR 显著更低，但样本量不足以单独立因果论证。 GPS 起点扰动 σ 从 0 增至 10 m，SR 在 0.065–0.095 间非单调波动，量级远小于指认噪声，几何鲁棒性尚未成为可观测约束。强制

退化几何（禁用检测框地理投影与重观测居中）使 SR 降至 0.025、全部回合耗尽 12 步预算、NE 升至 414 m, Fisher 精确检验显示该组 ($k = 5/n = 200$) 与主套件 B2 ($k = 16/n = 200$) SR 差异 $p = 0.023$ （表14 给出各组 95% Wilson 置信区间）。我们只报告该条件下的观测 SR 与显著性检验结果，不把“禁用投影”单一处理下的差异直接推广为“投影通道是到达能力的必要成分”这一更强的因果断言——消融同时改变了投影与重观测居中两个环节，无法互相分离。

表 13: Oracle 阶梯：导航与指认逐层替换为 oracle 后的到达能力（旧观测模型，事件隔离基准， $n = 200$ ）。

层级	设定	n	SR (95% CI)	semSR	NE (m)	SPL
L0	无 oracle (现状)	200	0.080 [0.050,0.126]	0.155	223.9	0.068
L1	oracle 指认	200	1.000 [0.981,1.000]	1.000	0.1	0.986
L2	oracle 初始定位 (指认仍生效)	200	0.500 [0.431,0.569]	0.550	148.5	0.381
L3	oracle 初始定位 + 指认	200	1.000 [0.981,1.000]	1.000	0.0	1.000

表 14: 端到端主消融与扰动套件（旧观测模型，事件隔离基准）。SR 附 Wilson 95% 置信区间。固定下降策略触发次数远小于回合数，因为触发仍受上游“存在损伤证据”门控。

套件	配置	n	SR (95% CI)	semSR	NE (m)	复检触发
主套件	B0	200	0.070 [0.042,0.114]	0.165	222.3	0
主套件	B1	200	0.080 [0.050,0.126]	0.155	223.9	0
主套件	B2	200	0.080 [0.050,0.126]	0.155	223.9	0
主套件	B3	200	0.080 [0.050,0.126]	0.140	305.7	0
复检策略族	E11_RANDOM	200	0.080 [0.050,0.126]	0.155	223.9	0
复检策略族	E11_FIXED	200	0.080 [0.050,0.126]	0.155	224.0	3
复检策略族	E11_ENTROPY	200	0.080 [0.050,0.126]	0.155	223.9	1
复检策略族	E11_INFOGAIN	200	0.080 [0.050,0.126]	0.155	223.9	2
复检策略族	E11_CONFORMAL	200	0.080 [0.050,0.126]	0.155	223.9	2
GPS $\sigma=2$ m	B2	200	0.065 [0.038,0.108]	0.140	230.7	1
GPS $\sigma=5$ m	B2	200	0.085 [0.054,0.132]	0.155	221.4	0
GPS $\sigma=10$ m	B2	200	0.095 [0.062,0.144]	0.200	238.6	0
强制退化几何	B2	200	0.025 [0.011,0.057]	0.075	414.4	0

6 局限与影响

当前绑定约束仍是损伤分类器在事件不相交测试上对中间损伤等级（轻微/严重损伤）召回持续偏低、开放词汇指认存在误报，而不是仿真平台或导航几何（oracle 指认下、指认仍生效时到达 $SR = 1.00$ ，GPS 扰动 $\sigma \leq 10\text{ m}$ 对 SR 无单调影响；该结论以本仿真的运动学假设——无风扰、无避障、无能耗约束——为前提，不外推到真实飞行）。类别加权训练把训练集 macro-F1 提升到 0.49–0.57，证明分类器有能力学到损伤线索，但同等条件下验证/测试 macro-F1 仅到 0.22–0.28，是真实的事件级泛化缺口，不是训练配方完全未处理不平衡的产物。与标准（非事件不相交）切分对照显示：换用文献常见的更宽松协议后 macro-F1 仅升至 0.31，离公开基线的 ~ 0.7 仍有明显差距。三方对照进一步测量了这一差距的构成：同一冠军架构，事件不相交重训的损伤 F1 仅 0.017，加载见过评测事件的现成权重为 0.630，差距约 97% 来自事件曝光——即跨事件泛化是瓶颈，架构与裁块尺寸不是充分解释。因此本文对重观测机制的考察建立在 leaky 底座上，不主张跨事件泛化。

视场收缩模型消除了“下降 = 撤销合成模糊”以及“把 0.5 m/px 写成 10 m 飞行”两处构造错误。信息上界仍然是源影像的 0.5 m/px ，低于该 GSD 的结构不可恢复；这条局限从人为设定变成了数据源固有，但不会消失。新几何与 leaky 底座上的前置检查测得逐建筑 $n_{\text{flip}} = 733$ 、 $n_{\text{correctable}} = 375$ ，但题目层面效应小且不单调 (MARGINAL)，因此不得把可识别性判定写成任务增益，也不得外推为真实降高无信息。重观测抬升的置信度绝对值仍过度自信（0.9 档实际正确率仅 41.8%），因此“按置信度可靠弃答”目前只提供**排序**意义上的可靠性，不能解释为良好校准的概率，其可兑现的覆盖率–准确率权衡有限；该价值是对“机制作用在概率而非标签”的诊断，而不是对弃答策略性能的正面主张。Esri 底图是非事件当天影像，仅作上下文；ROI 内恒为真实 xBD。只看图预测 ROI/来源的泄漏体检尚未运行，不能声称源差异已被实验排除。场景池限制为巡航覆盖 ≥ 0.80 (495/4312)，偏向建成区密集、条带重叠多的区域，midwest-flooding 与 guatemala-volcano 完全退出。期望熵查找表仍是旧合成阶梯产物，当前会被拒绝并回退启发式。在线闭环已切换到 xView2 冠军检测后端；但巡航档缓缓存端到端延迟约 8.3s 仍高于 2s/次的闭环门槛（主要来自原生 pre 渲染与逐框双时相分

类，批处理与 pre 分辨率上限尚未优化)。高度重标定使两次下降的等效航时与 12 步巡航同量级，旧文按 20 m 垂直机动所做的预算换算不再适用。

RescueNet 提供真实低空端点，但没有与 xBD 瓦片的逐栋地理配准，且缺乏灾前配对（差通道恒为 0），该结果只能作为域外可用性检查，不能单独支持“绑定约束在损伤头”的因果论证。语言条件搜索的指令空间仍偏模板化，尽管已加入方位、否定与多地标；在语言复杂度不足时不应自称完整 VLN。旧 40×3 设计统计功效不足；新基准规模按功效分析扩大，但仍需损伤证据阳性回合才能比较重观测策略。仿真不包含风扰、斜视、运动模糊、通信与电池。DisasterClaw 定位为决策支持，损伤结论应保留人工确认。地理影像可能暴露敏感位置，轨迹发布需按灾种做隐私审查。

7 结论

本文给出一套面向灾后侦察的语言条件智能体与地理配准仿真/监控平台，把航空应急侦察中的“再看一眼”写成预算受限的主动重观测。观测几何从合成模糊阶梯改为固定传感器、固定视场角的视场收缩：巡航 1330 m (1.50 m/px) 到下限 443 m (0.50 m/px)，信息上界由源影像原生 GSD 导出，题目锚定 ROI 使答案不随高度改变。系统贡献是工程存在性声明，不改变下述科学结论。

在旧合成阶梯上，损伤分类器预测几乎不随 GSD 翻转，机制不可识别；这一负结果经三组反事实排除后成立，不是训练流程缺陷。把问题换到新观测模型与一个公开披露的强感知底座上后，降高确实改变证据（逐建筑 $n_{\text{flip}} = 733$ 、 $n_{\text{correctable}} = 375$ ），但翻转有得有失，题目层面效应小且不单调（pilot 中固定下降纠正 4 题、破坏 2 题）。机制从“不可测”推进到“可测但小”，结论落在预注册的分支 C：主动重观测通道可识别，但不足以排序候选策略。进一步地，重观测的机制作用在**置信标定**而非定类：160 题基准上 93 次重观测中 74 次抬升置信度（均值 0.834 → 0.946），且置信度与正确率大致单调正相关（0.8 档 21.5%、0.9 档 41.8%、0.99 档 100%）。据此把重观测的价值定位为“按置信度可靠弃答”，而非提高准确率。

损伤分级坍塌的根源经三方对照测量：同一冠军架构，事件不相交重训的损伤 F1 仅 0.017，加载见过评测事件的现成权重为 0.630，差距约 97%

来自事件曝光、约 3% 来自架构。即跨事件泛化是当前系统的真实瓶颈，不是架构或裁块尺寸。这意味着本文对重观测机制的考察，本质上是在“模型已学会这些事件”的底座上完成的，结论的适用范围须据此收窄，不得写成跨事件泛化的重观测增益。

本文的瓶颈定位——跨事件泛化、重观测作用在置信而非标签——与独立第三方基准的瓶颈诊断方向一致：ESARBench 在 600 个搜救任务上同样把 MLLM-UAV 智能体的瓶颈归因于空间记忆与高层推理，而非平台或传感 [16]。两套环境、两类任务、同一结论方向，构成对“瓶颈在 MLLM 推理/泛化”这一判断的外部稳健性支持，但不构成对其普适性的证明。

端到端语言条件搜索不再承担唯一验证出口；历史全零成功的三处相互独立实现缺陷已全部修复，修复后的 oracle 阶梯把旧系统剩余瓶颈压在目标指认层（oracle 指认使严格 SR 从 0.08 到 1.00）。这一结论以本仿真无风扰/无避障/无能耗约束的运动学假设为前提，不外推到真实飞行。

参考文献

- [1] Peter Anderson, Qi Wu, Damien Teney, Jake Bruce, Mark Johnson, Niko Sünderhauf, Ian Reid, Stephen Gould, and Anton van den Hengel. Vision-and-language navigation: Interpreting visually-grounded navigation instructions in real environments. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 3674–3683, 2018.
- [2] Ruzena Bajcsy. Active perception. *Proceedings of the IEEE*, 76(8):996–1005, 1988.
- [3] Wele Gedara Chaminda Bandara and Vishal M. Patel. A transformer-based siamese network for change detection. In *IEEE International Geoscience and Remote Sensing Symposium*, pages 207–210, 2022.
- [4] Andreas Bircher, Mina Kamel, Kostas Alexis, Helen Oleynikova, and Roland Siegwart. Receding horizon “next-best-view” planner for 3d

- exploration. In *IEEE International Conference on Robotics and Automation*, pages 1462–1468, 2016.
- [5] Hao Chen, Zipeng Qi, and Zhenwei Shi. Remote sensing image change detection with transformers. *IEEE Transactions on Geoscience and Remote Sensing*, 60:1–14, 2022.
- [6] Sheng Fang, Kaiyu Li, Jinyuan Shao, and Zhe Li. SNUNet-CD: A densely connected siamese network for change detection of VHR images. *IEEE Geoscience and Remote Sensing Letters*, 19:1–5, 2022.
- [7] Yunpeng Gao, Zhigang Wang, Pengfei Han, Linglin Jing, Dong Wang, and Bin Zhao. Exploring spatial representation to enhance LLM reasoning in aerial vision-language navigation. *arXiv preprint arXiv:2410.08500*, 2024.
- [8] Chuan Guo, Geoff Pleiss, Yu Sun, and Kilian Q. Weinberger. On calibration of modern neural networks. In *Proceedings of the 34th International Conference on Machine Learning*, pages 1321–1330, 2017.
- [9] Ritwik Gupta, Richard Hosfelt, Sandra Sajeed, Nirav Patel, Bryce Goodman, Jigar Doshi, Eric Heim, Howie Choset, and Matthew Gaston. xBD: A dataset for assessing building damage. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, 2019.
- [10] Jungdae Lee, Taiki Miyanishi, Shuhei Kurita, Koya Sakamoto, Daichi Azuma, Yutaka Matsuo, and Nakamasa Inoue. CityNav: A large-scale dataset for real-world aerial navigation. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 5912–5922, 2025.
- [11] Shubo Liu, Hongsheng Zhang, Yuankai Qi, Peng Wang, Yanning Zhang, and Qi Wu. AerialVLN: Vision-and-language navigation for UAVs. In

- Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 15384–15394, 2023.
- [12] Yaniv Ovadia, Emily Fertig, Jie Ren, Zachary Nado, D. Sculley, Sebastian Nowozin, Joshua Dillon, Balaji Lakshminarayanan, and Jasper Snoek. Can you trust your model’s uncertainty? Evaluating predictive uncertainty under dataset shift. In *Advances in Neural Information Processing Systems*, volume 32, 2019.
- [13] Maryam Rahnemounfar, Tashnim Chowdhury, and Robin Murphy. RescNet: A high resolution UAV semantic segmentation dataset for natural disaster damage assessment. *Scientific Data*, 10:913, 2023.
- [14] Allen Z. Ren, Anushri Dixit, Alexandra Bodrova, Sumeet Singh, Stephen Tu, Noah Brown, Peng Xu, Leila Takayama, Fei Xia, Jack Varley, Zhenjia Xu, Dorsa Sadigh, Andy Zeng, and Anirudha Majumdar. Robots that ask for help: Uncertainty alignment for large language model planners. In *Conference on Robot Learning*, 2023.
- [15] Dhruv Shah, Blazej Osinski, and Sergey Levine. LM-Nav: Robotic navigation with large pre-trained models of language, vision, and action. In *Proceedings of The 6th Conference on Robot Learning*, volume 205 of *Proceedings of Machine Learning Research*, pages 492–504. PMLR, 2023.
- [16] Daoxuan Zhang, Ping Chen, Jianyi Zhou, and Shuo Yang. ESARBench: A benchmark for agentic UAV embodied search and rescue, 2026.
- [17] Weichen Zhang, Chen Gao, Shiquan Yu, Ruiying Peng, Baining Zhao, Qian Zhang, Jinqiang Cui, Xinlei Chen, and Yong Li. CityNavAgent: Aerial vision-and-language navigation with hierarchical semantic planning and global memory. In *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 31292–31309, Vienna, Austria, 2025. Association for Computational Linguistics.

A 附录：协议、切分与复现

事件切分。 训练: guatemala-volcano, hurricane-florence, hurricane-matthew, joplin-tornado, lower-puna-volcano, midwest-flooding, portugal-wildfire, santa-rosa-wildfire, socal-fire, sunda-tsunami, tuscaloosa-tornado, woolsey-fire。验证（温度拟合）: hurricane-harvey, mexico-earthquake。测试: hurricane-michael, palu-tsunami。留出: nepal-flooding, moore-tornado, pinery-bushfire。视场收缩场景池另加覆盖率门槛：巡航窗口真实 xBD 覆盖 ≥ 0.80 ，合格 495/4312 张有地理配准的灾后瓦片（表2）。midwest-flooding 与 guatemala-volcano 因此完全退出可用 ROI 池；这一偏倚属于场景定义，不是评测后筛选。覆盖率门槛不改变事件不相交协议：训练/验证/测试/留出仍按事件互斥。

视场阶梯常量。 传感器边长 1024 px，水平视场角 60° ，瓦片跨度 512 m。下限 $h_{\min} = 443.405$ m（1.0 瓦片，0.50 m/px），巡航 $h_{\text{cruise}} = 1330.215$ m（3.0 瓦片，1.50 m/px），单步下降 443.405 m。实现细节见仓库可复现性文档。默认使用视场收缩马赛克视图；旧合成模糊路径仅用于复现历史产物，新实验不得使用。

底图来源。 Esri World Imagery, attribution: Tiles © Esri —Source: Esri, Maxar, Earthstar Geographics, and the GIS User Community。缓存未命中且无网络时必须报错，不得静默返回灰图。Esri 影像不参与 ROI 内真值或评分。

感知底座双轨。 轨 A 的封装与产物必须标记为 leaky（现成冠军权重，见过评测事件），不得进入正式主表；轨 A 权重在官方 train+tier3 上训练，见过测试/留出事件。轨 B（事件不相交重训）已完成：损伤 F1 0.017，与轨 A 的 0.630 差距约 97% 来自事件曝光。在线感知默认已切换到轨 A（冠军检测后端），自训练路径保留为可回退对照。

预注册假设（保持）。 H1：温度缩放降低事件不相交测试 ECE 且不改变精度。H2：差分注意力相对拼接的均匀精度/校准优势。H3–H4：信息增益

或共形触发相对无/随机/固定下降的判断增益。零触发回合对条件 ΔU 视为缺失，触发率报 0，不得填补成功下降。新观测模型构成新系统，其预注册（配置冻结、判据、留出事件）与 pilot/留出已按新协议执行；旧留出已经消费，不得重跑，也不得因其结果调节新机制。新系统的留出事件为 moore-tornado 与 nepal-flooding (pinery-bushfire 因覆盖率门槛下候选过少而剔除)，与 pilot 事件 (hurricane-michael、palu-tsunami) 互斥。

H2 结果。 差分注意力与拼接融合在事件不相交切分下的验证/测试 macro-F1 互有胜负（表3）：拼接在验证集选择指标上略高，差分注意力在测试集“损毁”召回上更高。按预注册规则，H2 判定为“在当前样本量下无法区分”，两种融合方式均不获得“均匀优势”结论。

损伤分类器训练修复。 复核发现早期版本训练日志汇报的验证集 accuracy (≈ 0.80) 具有误导性：在完好类占比 66%–79% 的数据上，未加权交叉熵 + 按 accuracy 选模型快照会系统性收敛到常数预测器，训练集自身 macro-F1 当时也只有 ≈ 0.22 – 0.25 （三类损伤召回接近 0），说明问题出在训练配方而非某次评测脚本的 bug。修复：(i) 类别加权交叉熵（训练集逐类频率倒数）；(ii) 模型选择改为验证集宏观 F1；(iii) 训练收尾对重载后的模型快照现场核验，数值与训练期间记录不一致则拒绝保存。另需记录一次排查过程中的假警报：复核者最初误用一份早期废弃的、非事件不相交的小规模数据目录 (xbd_change/) 复算验证集表现，得到与训练日志严重不符的数字，一度怀疑存在模型快照保存/加载 bug；改用训练时真正使用的事件不相交目录 (xbd_change_strict_v1/)，与本节“事件切分”一致后，重载数值与训练日志完全吻合，排除了保存/加载环节的 bug，问题精确定位到训练配方本身。如实记录该假警报是为了让复现者不必重复同一轮排查。

标准（非事件不相交）切分基线。 采用与公开 xBD/xView2 基线一致的协议：train/tier3 内按图块 95/5 随机切分为 train/val，官方 test 目录作为 test，holdout 灾害事件仍整体排除。该协议下同一灾害事件的图像可同时出现在 train 与 test，只是不同图块。

权重溯源 (SHA-256 前 16 位)。 权重以 SHA-256 前 16 位哈希溯源，全部文件哈希、字节数与环境快照内嵌于每次评测的产物中。早期未加权的对照版本保留在仓库中，不再用于正文结果。xView2 冠军权重为四架构 $\times$ 定位/分类 $\times$ 3 种子的集成；凡使用这些权重的评测必须标记为 `leaky`。

复现入口。 数据根目录由环境变量给出（事件不相交切分与官方标准切分分别对应不同根目录），不在正文写绝对路径；项目环境为统一声明的依赖环境。复现入口（视场几何与马赛克不变量单元测试、损伤分类器重训、逐类指标导出、检测器离线对照、全量实验）以脚本形式随仓库发布，正文不逐一罗列命令。本地视觉语言模型以本地离线推理加载（权重体积与常驻内存占用显著），无需外部服务，以保证离线可复现。投稿前将本中文 LaTeX 按《航空学报》Word 模板转写；表图由 `paper_cja/generated` 导出。截图步骤见仓库文档。