

DisasterClaw : 校准不确定性驱动的预算
受限主动重观测
用于双时相航空灾害损伤评估

作者 (投稿前填写)

目录

1	引言	3
2	相关工作	5
3	系统架构与仿真平台	6
3.1	双模式智能体与有限动作集	6
3.2	地理配准仿真世界	7
3.3	人机协同控制台: 平台实际能做的事	8
3.4	分层语义规划与记忆栈	8
4	方法与实验协议	11
4.1	预算受限主动重观测	11
4.2	高度-有效 GSD 分辨率阶梯	12
4.3	双时相损伤分类与校准	12
4.4	触发策略	13
4.5	事件不相交数据协议	13
4.6	运动学参数与预算换算	13
4.7	评价指标与可识别性判据	14

目录	2
5 实验	14
5.1 训练/验证曲线、类别加权与基线对标	14
5.2 有效 GSD 与分类质量	16
5.3 预算受限观测分配	16
5.4 功效分析与事件隔离基准	19
5.5 RescueNet 低空评估域	21
5.6 端到端缺陷与探索回退	21
5.7 Oracle 阶梯与端到端现实检验	23
6 局限与影响	24
7 结论	26
A 附录：协议、切分与复现	30

摘要

语言引导的航空应急侦察需要同时完成目标搜索与损伤判定。本文给出一套已实现的双模式智能体与仿真/监控平台：操作员以自然语言下达任务，系统在地理配准的俯视仿真中闭合感知-规划-执行回路，并提供实时人机协同控制台。在该平台上，我们将“第一次俯视是否足够”表述为**预算受限的主动重观测**：用事件不相交训练的双时相损伤分类器给出校准概率，再把证据是否足够转成一次可审计的下降-居中动作，并用有效 GSD 把高度变成可测物理量。科学问题从导航链条中解耦，在事件不相交的双时相建筑裁块上比较不下降、随机、未校准熵、校准熵、条件期望熵、共形集合以及 oracle 参照。该机制在当前分类器上**基本不可识别**，但我们没有止步于此：外部审稿指出“损伤头先失败”这一归因此前从未有训练/验证集证据支撑，可能只是第四处未被发现的实现缺陷。为此补做训练曲线核查、类别加权重训与公开协议对标三组实验。结果显示：类别加权训练下训练集 macro-F1 可升至 0.49–0.57（排除“从未训练成功”），但事件不相交验证集 macro-F1 全程停留在 0.21–0.25，是一条干净的“训练内有信号、跨事件不泛化”曲线，构成事件级域偏移的直接证据。换到官方标准（非事件不相交）切分重训同一架构，测试 macro-F1 从 0.22 升至 0.31，表明协议难度只能解释与文献 ~ 0.7 基线之间差距的一小部分，多数差距应归因于本文架构/训练规模的局限，而非域偏移本身。类别加权后端到端指标略有改善（“损毁”类召回从 0.007 恢复到 0.16），但仍不足以让任何观测分配策略在宏观 F1 上跑赢随机或 oracle 参照。端到端历史全零成功被拆解为三处独立实现缺陷（探索恒向北、机载视场零提议、系统性早停）并全部修复；修复后的 oracle 阶梯把剩余瓶颈定位到目标指认层：oracle 指认使 200 题严格成功率从 0.08 升至 1.00，而 oracle 初始定位（指认仍生效，非严格意义的“oracle 导航”）仅得 0.50。本文贡献分两层：可运行的智能体系统与仿真平台是工程存在性声明；可审计协议、经过反事实排除的负结果归因与瓶颈定位是科学结论。二者不得混读为复检已经提高任务成功率。

1 引言

洪涝、地震与野火之后，指挥员更希望对无人机说“检查道路北侧那栋完全损毁建筑”，而不是给出精确坐标。执行这类指令需要语言条件目标搜索、导航与损伤评估，并且必须承认：第一次俯视观测常常不够。鸟瞰条件

下,小目标、配准误差、类别极不平衡以及卫星-低空域偏移都会使一次性置信判断不可靠。

视觉语言导航(VLN)多在第一人称三维环境中研究 [1, 11]。灾害测绘则广泛使用地理配准的星载或航拍影像与灾前/灾后配对,如 xBD/xView2[9]。空中语言导航近期进一步引入分层语义规划与拓扑记忆 [16, 7, 15]。本文连接上述线索,构建一套面向灾后侦察的语言条件智能体,并在该系统上检验校准不确定性驱动的主动复检。验证出口刻意分层:把“校准不确定性能否转化为更好的观测分配”放在离线、无导航的预算实验中回答;把“现有栈在哪一层失败”放在 oracle 阶梯中诊断;把完整飞行闭环作为现实检验;把系统本身作为可运行、可复现的工程载体单独陈述(第3节),不把模块存在性写成任务增益。中心机制的形式化(动作集、归一化熵、期望熵减、共形触发)见 第4.1节。

本文贡献如下。

- **智能体系统与仿真/监控平台** (工程存在性声明): 双模式编排器(一次性任务规划与闭环语言导航)、分层语义规划与记忆栈、地理配准 xBD 俯视仿真,以及实时人机协同控制台。这些模块已实现并可复现(第3节)。该声明不蕴含导航成功率或复检增益;尤其禁止把定位 Dice、提议召回或记忆图的存在写成判断/到达改善。
- 面向航空应急侦察的任务定义: 把校准不确定性转为预算受限的下降-居中动作,并以有效 GSD 作为物理可审计量。
- 离线观测分配实验: 在事件不相交裁块上比较校准/未校准/共形/oracle 参照。当前分类器下预测几乎不随 GSD 翻转,机制主张在该数据上不可识别。
- **对该负结果的反事实排除**: 训练/验证曲线核查排除“分类器从未训练成功”,类别加权重训排除“完全未处理类别不平衡”,标准切分基线对标把“评测协议过严”与“架构/训练规模不足”两个可能原因分离——这一组诊断实验本身构成把负结果与实现缺陷区分开的可复用方法论。
- 泄漏安全协议与诊断: 事件级切分、功效分析、oracle 阶梯瓶颈归因

(指认层, 附命名修正)、以及 RescueNet 低空评估域。端到端历史全零成功的三处实现缺陷排查记录在 第5.6节, 作为可复现性说明而非独立科学贡献。

2 相关工作

航空应急侦察与鸟瞰导航。 无人机已被用于灾后快速测绘与建筑物损伤初判。AerialVLN 等将 VLN 扩展到空中平台 [11], CityNav 则强调地理配准的城市鸟瞰导航 [10]。本文工作在地理配准的俯视仿真中进行, 指令当前仍以损伤类别与方位约束为主, 故正文采用“语言条件目标搜索”, 避免对标室内 R2R 的过度框架。

分层语义规划与拓扑记忆。 CityNavAgent 用大语言模型把空中 VLN 拆成地标、目标与运动三层, 并以全局拓扑记忆压缩长程动作空间 [16]。STMR 把俯视语义地图写成供语言模型阅读的数字网格, 强调语义、拓扑与度量应同时进入提示 [7]。LM-Nav 则把语言模型抽地标、视觉语言模型对齐节点与图搜索沿熟路执行组合起来 [15]。本文借用这三条设计, 适配到二维地理鸟瞰与有限动作集; 实现细节见 第3.4节。这是架构借鉴, 不是与上述系统的性能对标; 端到端消融中打开记忆图并未改善严格成功率 (第5.7节)。

遥感变化检测与 xBD 损伤评估。 xBD 提供灾前/灾后配对与四级 FEMA 风格损伤标签 [9]。后续变化检测工作 (BIT、ChangeFormer、SNUNet 等) 表明, 显式建模时相差分有助于变化定位, 但不自动带来校准良好的类概率 [5, 3, 6]。xView2 优胜方案通常把建筑定位与损伤分类分开。本文只借用定位阶段作为可替换脚手架, 损伤头保持双时相分类器不变, 且禁止加载公开冠军权重以免泄漏。RescueNet 提供与 xBD 四级损伤对齐的低空无人机分割标注 [13], 本文仅用作评估域。

主动感知与 Next-Best-View。 主动感知主张运动与传感联合选择 [2]。三维探索中的 receding-horizon next-best-view 规划是航空机器人的经典工具 [4]。本文将动作集收窄为 {hold, descend_center}, 以便在双时相分类器上把“再看一眼”做成可对照的预算分配问题。

校准、分布偏移与共形预测。 温度缩放是深度网络校准的标准后处理 [8]。分布偏移下校准往往先于精度崩溃 [12]。机器人规划中已有用共形预测决定“何时求助”的先例 (KnowNo) [14]。本文将共形集合大小作为与校准熵并列的触发器，强调覆盖保证而不是把信息增益过度声明为贝叶斯最优。

不确定性内省与具身智能。 具身智能需要知道何时观察不够。本文不把端到端成功率为零解释为“机制无效”：若上游从未产生损伤证据，复检控制器根本没有被执行。这是实验设计问题，也是本文把机制研究从导航链解耦的原因。

3 系统架构与仿真平台

本节描述已实现并可复现的智能体系统与仿真/监控平台。它是后续机制实验的运行载体，不是对导航成功率或复检增益的度量声明；度量结论见 第5.2节–第5.7节。操作界面见图 1 与图 2–5；截图拍摄步骤见仓库 `paper_cja/SCREENSHOTS.md`。

3.1 双模式智能体与有限动作集

系统由 Flask + Socket.IO 后端与 React 前端构成，面向单架无人机、正射地理鸟瞰。编排器提供两种互补模式，动作空间显式、有限，不是开放的工具调用循环：大语言模型只负责规划与指认，状态机在 Python 侧闭合。

任务规划模式。 操作员在控制台输入一条自然语言任务（例如“飞到选点上空 30 m 悬停并做受灾检测”）。规划器调用语言模型，一次性输出固定模式的动作序列，字段为 `{action, params, reason}`；语言模型不可达时按关键词与经纬度规则回退。执行器按序调用同一套底层动作，并在控制台逐步回显计划与日志。

语言导航模式。 操作员输入目标描述（例如“飞到北侧寻找完全损毁的建筑”）。系统进入感知–决策–执行闭环：每步按当前经纬高裁剪机载视场，运

行检测/分割/双时相损伤分类，可选地由复检控制器发出下降-居中，再由导航器输出相对位移、悬停或停止。导航器可切换为关键词贪心基线（套件 B0）或分层语义规划模块 HSPM（B1-B3 与 oracle 阶梯默认，见 第3.4节）。

底层动作。 两种模式最终都落到同一动作表：fly_to_geo（飞到经纬高，必要时对齐最近的灾后瓦片）、fly_relative（北-东-天相对位移）、hover、detect_disaster（裁视场并跑感知栈）、mark_target、report_observation。语言导航另把 stop 作为回合终止符。复检不是第 7 种独立动作枚举，而是在闭环内插入的 fly_relative（先水平居中、再下降 10 m）。

感知栈。 机载视场半径随高度线性变化（默认 $\text{radius} = \text{clip}(2 \cdot h, 20, 300) \text{ m}$ ），再按瓦片地面采样距离裁成至少 256×256 的正射块。块上并行：建筑提议（默认仅在训练事件灾前瓦片上训练的 ResNet34 U-Net，同切分 YOLO 作对照）、场景分割（SegFormer）、双时相损伤分类，以及进程内加载的 Qwen2.5-VL-7B 开放词汇指认与灾情摘要。混合指认路径为检测器类别命中优先、视觉语言模型兜底。禁止把定位 Dice 或提议召回写成导航或判断增益。

3.2 地理配准仿真世界

仿真世界把 xBD 灾后（POST）瓦片按地理足迹叠到真实底图上，像素-经纬度由瓦片仿射给出，原生地面采样距离约 0.5 m/px 。操作员可按灾害事件浏览瓦片目录、按损毁评分排序、一键激活瓦片并把无人机锚到瓦片中心；点选地图外位置时，系统会查找最近的 POST 覆盖并提示是否跳转，避免在无影像区域空飞。建筑多边形按 FEMA 四级着色，供操作员对照，**不作为智能体的作弊输入。**

运动学为二维匀速直线插值，不是六自由度飞控：水平速度 $4\text{--}14 \text{ m/s}$ （默认飞向地理点 14 m/s 、相对位移 12 m/s ），巡航高度 30 m ，高度下限 10 m ，不含风扰、惯性、避障与电池消耗。视场随高度收缩；离线机制实验里再把高度写成有效 GSD 阶梯（第4.2节）。数值预算与步长约定见 第4.6节。

3.3 人机协同控制台：平台实际能做的事

前端是实时监控/控制台，不是评测脚本的附属页面。操作员可以完成下列闭环，全部经 Socket.IO 推送世界状态、感知结果与思维链。

1. **选区与对照**。切换底图（卫星/街道）、叠加 xBD 灾后影像、显示或隐藏建筑足迹与瓦片边界；在真实地理坐标上看到无人机图标与飞行轨迹。
2. **手动飞行**。点地图飞向该点、悬停、标记兴趣点；左栏持续显示经纬高、航向、速度与锚点北东偏移。
3. **点选巡检**。在疑似受损建筑上发 Inspect：自动生成任务规划序列，飞到 30 m 悬停后跑 `detect_disaster`。底栏可在“UAV 视场 / YOLO 标注 / SegFormer”三页签间切换，并显示风险等级、受损/完好/车辆计数与可选的视觉语言模型摘要。
4. **语言目标搜索**。在 VLN 框下发一句话指令，无人机逐步感知并自主飞向目标；底栏显示当前技能、是否命中、距离、语义栅格统计（已探索格、地标、候选目标）以及复检不确定性条。
5. **一次性任务规划**。在 AI Task 框下发复合任务，右侧列出逐步动作与理由，底栏日志同步执行过程，可随时 Stop。
6. **独立视觉问答**。控制台可上传任意图片调用同一套视觉语言模型做灾情分析，不依赖当前视场。

上述能力用于人机协同演示与单题排错；正文的成功率数字来自无界面的批处理评测脚本，二者不得混用账本。

3.4 分层语义规划与记忆栈

语言导航闭环默认使用分层语义规划（HSPM），对照 B0 为关键词贪心基线。设计借鉴 CityNavAgent 的三层分解 [16]，适配到二维地理鸟瞰：地标层由语言模型把指令拆成有序子目标；目标层在当前子目标不可见时，把语义地图局部窗口交给语言模型做方位常识推理（OROI）；运动层把“可




图 1: 系统分层：操作员经实时控制台驱动编排器，编排器调用语言模型、感知、规划与记忆模块，在地理配准仿真世界上执行有限动作集。




图 2: 控制台全貌：顶栏模式切换，左栏无人机位姿，中栏地理配准态势图，右栏任务规划与语言导航输入，底栏感知与日志。

待补截图 `paper_cja/figures/map_overlay.png`
拍摄步骤见 `paper_cja/SCREENSHOTS.md`

图 3: 态势地图局部: 灾后卫星叠加、按损伤等级着色的建筑足迹、无人机图标与轨迹。建筑足迹仅供操作员对照, 不进入智能体观测。

待补截图 `paper_cja/figures/inspect_perception.png`
拍摄步骤见 `paper_cja/SCREENSHOTS.md`

图 4: 点选巡检后的感知三视图: 机载视场、检测框与场景分割; 右侧为风险摘要与可选视觉语言模型结论。

待补截图 `paper_cja/figures/vln_closedloop.png`
拍摄步骤见 `paper_cja/SCREENSHOTS.md`

图 5: 语言导航进行中: 地图轨迹、当前指令、技能与命中状态、语义栅格统计及复检不确定性。

见则朝质心步进、不可见则按方位探索”写成一次相对位移，动作仍落在 $\{\text{fly_relative}, \text{hover}, \text{stop}\}$ 。本文不做与 CityNavAgent 的性能对标。

目标层不把俯视图直接交给视觉语言模型，而是把五层地理语义栅格（当前视场、已探索、地标、周边目标、候选目标）渲染为以无人机为中心的网格、图例与目标方位摘要（STMR）[7]。与原 STMR 的差异在于：本文已有真实地理参考，矩阵由二维语义地图直接切片，无需深度反投影。STMR 随 HSPM 一并启用，不是单独开关。

当语言模型或视觉语言模型不可达时，探索回退为螺旋搜索，禁止无方向先验时每步默认向北。判到达半径（35 m）大于成功半径（25 m），故判到达后先平移至目标估计位置正上方再停止。Oracle 指认与 oracle 初始定位用于阶梯诊断，不作为上线策略。

跨任务拓扑记忆把成功轨迹沉淀为节点（观测航点）与边（地表距离），下次相似指令先按文本匹配对齐地标、再用最短路沿熟路预飞 [15]。环境变量默认关闭（VLN_MEMORY=0）；端到端消融中仅 B3 打开。B3 在既有结果上并未提高严格成功率，导航误差反而变差（第5.7节），因此记忆图不得写成已验证的增益模块，只作为可开关的系统能力报告。

4 方法与实验协议

4.1 预算受限主动重观测

语言导航闭环给出候选建筑后，决策问题收窄为：当前观测的校准概率是否足以定类，若否，是否花一次额外航时去下降并居中。动作集为

$$\mathcal{A} = \{\text{hold}, \text{descend_center}\}. \quad (1)$$

hold 保持巡航高度继续使用当前裁块；descend_center 先平移到目标估计位置正上方，再下降固定高度步长（默认 10 m），在更细的有效 GSD 上重跑损伤头。平均每样本允许 B 次额外原生档观测；每位置与每回合次数有硬上限（同一位置最多 2 次复检）。

给定四类损伤的校准概率 $p_t \in \Delta^{K-1}$ ， $K = 4$ ，定义归一化熵

$$U_t = -\frac{1}{\log K} \sum_{k=1}^K p_{t,k} \log p_{t,k} \in [0, 1]. \quad (2)$$

下降动作的预期收益不是手调高度比，而是在验证裁块上拟合的条件期望熵减

$$\widehat{\text{IG}}(a) = U_t - \mathbb{E}[U \mid \text{GSD}(a), \hat{y}_t], \quad (3)$$

其中 $\text{GSD}(a)$ 由高度-分辨率阶梯给出， $\hat{y}_t = \arg \max_k p_{t,k}$ 。 $\widehat{\text{IG}}$ 是查找表意义上的期望熵减，不是 Shannon 信息增益的无偏估计，不得写成贝叶斯最优。并列方法用分拆共形预测：当预测集合 $|C(x)| > 1$ 时认为证据不足以唯一定类，从而触发重观测，并报告 $1 - \alpha$ 覆盖。

4.2 高度-有效 GSD 分辨率阶梯

xBD 只有单一原生分辨率（约 0.5 m/px）。若下降只是裁小窗口再把分类裁块双线性缩放到固定 96×96 ，则不引入新信息。为此定义线性阶梯：巡航高度 30 m 对应 $4\times$ 降采样加高斯模糊，最低高度 10 m 对应原生像素，中间高度内插尺度。有效 GSD 写入每步观测日志，使式 (3) 的条件期望成为可拟合的量。

该构造的适用范围必须写明：仿真中的“下降”等于逐步撤销我们自己加上的模糊，最好情况下测到的是分类器能否从合成降质中恢复，而不是真实 10 m 飞行所提供的厘米级新纹理。因此后文零结果只约束“在该有效 GSD 阶梯上机制是否可识别”，不能外推为“真实降高无信息”。

4.3 双时相损伤分类与校准

共享编码器分别提取灾前/灾后特征，融合后接四类损伤头与二值变化头（多任务）。两种融合方式并列评测（预注册 H2）：**拼接** ($[f_{\text{pre}}, f_{\text{post}}, f_{\text{post}} - f_{\text{pre}}]$) 与 **差分注意力** (D2ANet 式门控：先对 $[f_{\text{pre}}, f_{\text{post}}]$ 学通道门控再相减，再对差分特征学第二层门控)。正文实验默认报告差分注意力档；表1 给出两者的正式对比。验证集上拟合标量温度 T ，推理用 $\text{softmax}(\text{logits}/T)$ 。温度缩放不改变 $\arg \max$ ，故期望校准误差 (ECE) 改善不得写成识别精度改善。宏观 F1、分类型可靠性与总体 ECE 一并报告，以避免基率混淆。

类别加权与按宏观 F1 选择 checkpoint。 训练集完好类占比 66%–79%，早期版本用未加权交叉熵训练、按验证集 overall accuracy 选最佳 epoch，

这一组合在该不平衡度下会系统性选出常数预测器。修复为：(i) 交叉熵按训练集逐类频率倒数加权；(ii) 模型选择与早停均改用验证集宏观 F1；(iii) 每次训练收尾对重新加载后的 checkpoint 现场核验宏观 F1 与 accuracy 与训练期间记录值一致，不一致则拒绝保存。训练/验证曲线与逐类召回见第5.1节。

4.4 触发策略

条件期望熵。 在验证裁块上按 GSD 档与预测类统计平均熵，得到查找表 $\hat{\mathbb{E}}[U \mid \text{GSD}, \hat{y}]$ 。在线触发当 $\widehat{\text{IG}}(\text{descend_center})$ 超过阈值且预算未耗尽。若表缺失则回退到高度比启发式，并在日志中标明。

共形集合。 在验证集上用 Adaptive Prediction Sets 拟合分位数 $\hat{q}_{1-\alpha}$ 。预测集合取累积概率达到 $\hat{q}$ 的最小标签子集；当 $|C(x)| > 1$ 时触发下降。

对照包括：永不下降、随机花预算、未校准峰值/熵阈值、固定下降。零触发回合对条件熵差视为缺失，触发率报 0，不得填补成功下降。

4.5 事件不相交数据协议

灾害事件而非作物块是划分单位。训练、温度拟合（验证）、测试与留出使用互斥事件集合，见附录。任一评测题的 `disaster` 落入训练或验证集合即视为泄漏并在生成脚本中断言失败。题库审核字段记录为“模型辅助审核 + 作者抽查”，不得写成纯人工审核。

4.6 运动学参数与预算换算

语言导航默认步数预算 12，判到达半径 35 m，成功半径 25 m，朝目标单步上限 80 m，未命中时探索步长 90 m。复检每次下降 10 m，同一位置最多 2 次，水平居中位移上限 40 m。仿真器为实时演示把单段飞行时长封顶为 8 s，因此墙钟时间不能当作航时；按距离/速度换算、忽略该封顶：探索步 90 m 约 7.5 s，12 步巡航约 90 s；两次下降共 20 m 约 1.7 s，一次 40 m 居中约 3.3 s。离线实验中平均每样本额外观测预算 $B = 0.25$ 对应每四个裁

块一次下降—居中，相对 12 步巡航预算约为数个百分点的等效航时，而不是电池或气动模型。该换算只给出数量级，不能外推到真实续航。

4.7 评价指标与可识别性判据

端到端到达指标如下，首次出现即给出定义，后文用缩写。**严格成功率** SR：回合终止时无人机与目标的水平距离 $\leq 25\text{ m}$ 的比例。**语义成功率** semSR：在指令所述损伤类别的真值建筑集合上，距离最近真值 $\leq 25\text{ m}$ 的比例；它宽于 SR，不得写成严格成功。**导航误差** NE：终止位置到目标的水平距离（米），报告均值。**路径效率** SPL：成功回合按最短路径与实际路径长度比加权，失败回合记 0，再对题平均。

离线判断指标为总体精度、宏观 F1、ECE，以及预测翻转次数

$$n_{\text{flip}} = \#\{i : \hat{g}_i^{\text{cruise}} \neq \hat{g}_i^{\text{native}}\}. \quad (4)$$

可识别性判据预先写明，而不是为负结果事后找解释：若 n_{flip} 过小，或校准策略与不下降、随机之间的宏观 F1 差距（相对逐样本翻转参照）含 0，则任何预算分配策略在该数据上都**不可识别**——正确结论是机制未得到检验，而不是机制无效于导航。逐样本翻转知识的贪心分配是宏观 F1 的参照而不是上界：宏观 F1 对样本不可加，策略曲线超过该参照并不构成逻辑矛盾，后文改称“oracle 参照”。

5 实验

实验按自下而上顺序报告：先分类器能力核查，再有效 GSD 与观测分配，再功效与基准，最后 oracle 阶梯与端到端现实检验。不把定位提升写成导航贡献，也不把 semSR 当作严格成功。评价指标与可识别性判据见第 4.7 节：若巡航档与原生档几乎不翻转，则预算分配策略不可识别。

5.1 训练/验证曲线、类别加权与基线对标

审稿意见 C1 指出：本文此前从未报告损伤分类器在训练/验证集上的逐类表现，因此“损伤头先失败”这一归因无法与“训练本身失败（数据/标签 bug）”区分。我们据此补做三组对照实验，结果汇总于表 1 与表 2。

训练曲线：确有信号，但不跨事件泛化。 按第4节的类别加权 + macro-F1 选择重训后，训练集 macro-F1 随 epoch 从 0.22 单调升至 0.49–0.57（表2），说明分类器确实学到了区分损伤等级的视觉线索，排除“从未训练成功”这一竞争解释。但验证集（hurricane-harvey、mexico-earthquake，与训练事件不相交）macro-F1 全程停留在 0.21–0.25，不随训练集拟合程度提升而改善，验证损失反而缓慢上升（过拟合）。这是一条干净的“训练内有信号、跨事件不泛化”曲线，构成事件级域偏移的直接证据，而不是训练流程 bug 的证据。

类别加权部分缓解塌缩，但未逆转。 表1 对比未加权（论文早期版本）与类别加权（当前版本）checkpoint：测试集 macro-F1 从 0.220 升至 0.276，“损毁”类召回从 0.007 恢复到 0.164；但“轻微损伤”与“严重损伤”召回仍接近 0。加权训练有效但不充分，核心瓶颈判断不变。

与标准（非事件不相交）切分对照，拆分协议难度与架构差距（C2）。 本文刻意使用比公开 xBD 基线更严格的事件级切分（不同灾害事件，见第5.1节前言），但由此产生的 macro-F1 ≈ 0.7 （文献常见数值）与本文 ≈ 0.28 之间的差距，可能来自 (i) 评测协议更难，也可能来自 (ii) 本文架构/训练配方偏简单（轻量 ResNet18 双塔、8 epoch、无集成）。我们用同一架构在**官方标准切分**（图像级随机切分，训练/测试可共享灾害事件，与文献协议一致）上重训一次以分离两个因素：测试集 macro-F1 升至 0.308（表1 末行）——比事件不相交高约 0.03–0.04，但仍远低于文献的 ~ 0.7 。据此，协议难度只能解释差距的一小部分（ $\lesssim 0.04$ ），大部分差距（ $0.31 \rightarrow 0.7$ ）应归因于架构/训练规模的局限，应作为本文的诚实局限性陈述（第6节），而不是继续在本文内追赶公开基线的理由——直接借用公开预训练权重会因其训练集覆盖本文全部 val/test/holdout 事件而构成泄漏（见第2节、附录）。

H2：差分注意力与拼接融合无统计显著差异。 表1 第 2、3 行对比同一事件不相交切分下的两种融合方式：拼接在验证集选择指标上略高（macro-F1 0.241 vs. 0.222），差分注意力在测试集“损毁”召回上明显更高（0.164 vs. 0.055），两者互有胜负，样本量下不足以判定何者更优。H2 的结论是“在本数据规模下无法区分”，而非任一方向的优势。

表 1: 新旧 checkpoint、两种融合架构与两种切分协议的 macro-F1 / 逐类召回对照。

checkpoint	train F1	val F1	test F1	test 完好召回	test 损毁召回
旧 (未加权, 论文原用)	0.242	0.221	0.220	0.989	0.007
v2 差分注意力 (加权)	0.348	0.222	0.276	0.973	0.164
v2 拼接 (加权, H2 对照)	0.370	0.241	0.265	0.951	0.055
标准切分拼接 (加权, 协议对照)	0.330	0.350	0.308	0.995	0.233

5.2 有效 GSD 与分类质量

表3 给出重训后 (类别加权、差分注意力) checkpoint 在巡航档到原生档的精度、macro-F1 与 ECE ($n = 400$, 事件不相交测试集)。原生档预测为“完好”381、“损毁”19, 巡航-原生预测翻转 7 次 (表4)。配对 bootstrap 下原生档相对巡航档的精度差均值为 -0.0025 , 95% 置信区间 $[-0.0125, 0.0075]$ 含 0, 验收仍为 `accept_native_better=false`。macro-F1 在五档间为 0.273–0.286, 较未加权版本的 0.184 平坦值有提升但仍以完好类为主。

为排除“4× 降质过弱”, 另将尺度加到 8× 与 16× (有效 GSD 4m 与 8m): 预测分布与翻转次数无实质变化 (单元测试确认降质本身会改变高频像素, 因此不是空操作)。当前损伤头对纹理的敏感度不足以支撑跨 GSD 的信息增益估计, 但方向已不再反常——见图 6。

5.3 预算受限观测分配

设定: 每样本平均允许 $B \in \{0, 0.1, 0.25, 0.5, 1.0\}$ 次原生档观测。策略为不下降、随机、未校准熵、校准熵、条件期望熵、共形集合以及已知标签是否翻转的 oracle。类别加权 checkpoint 重跑后, 400 个配对样本中巡航预测与原生预测相差 7 例 ($n_{\text{flip}} = 7$, 较未加权版本的 1 例增加, 但绝对量仍很小)。表5 中各策略在 $B = 0.25$ 时 macro-F1 集中在 0.277–0.286, oracle 参照与不下降之间的差距仅 0.0094, `accept_calibrated_better=false` 依旧成立。可分配信息量随分类器改善而略有增加 (n_{flip} 从 1 到 7), 但幅度仍不足以让任何触发策略在宏观 F1 上跑赢随机或不下降。表中 ECE 出现

表 2: 类别加权训练下的逐 epoch train/val macro-F1 (C1 证据: 训练内有信号、验证集不改善)。

配置	epoch	train macro-F1	val macro-F1	train acc	val acc
差分注意力 (事件不相交, 加权)	1	0.220	0.222	0.735	0.797
	2	0.275	0.208	0.735	0.673
	3	0.336	0.224	0.757	0.755
	4	0.376	0.224	0.787	0.754
	5	0.400	0.216	0.796	0.720
	6	0.414	0.215	0.798	0.719
	7	0.438	0.220	0.804	0.745
	8	0.486	0.223	0.804	0.786
拼接 (事件不相交, 加权)	1	0.242	0.232	0.729	0.788
	2	0.294	0.219	0.733	0.704
	3	0.325	0.213	0.737	0.683
	4	0.411	0.247	0.784	0.783
	5	0.449	0.208	0.807	0.675
	6	0.498	0.225	0.814	0.782
	7	0.541	0.220	0.819	0.774
	8	0.568	0.224	0.824	0.779
拼接 (官方标准切分, 加权)	1	0.219	0.213	0.755	0.741
	2	0.266	0.310	0.748	0.740
	3	0.313	0.213	0.749	0.741
	4	0.395	0.318	0.777	0.760
	5	0.451	0.294	0.793	0.753
	6	0.481	0.344	0.795	0.767
	7	0.519	0.333	0.800	0.761
	8	0.559	0.325	0.806	0.765

表 3: 事件不相交测试裁块上的高度-GSD 阶梯 ($n = 400$, 类别加权 check-point)。

尺度 / 有效 GSD	精度	macro-F1	ECE	平均熵
1.00× / 0.50 m	0.623	0.286	0.042	0.776
1.75× / 0.88 m	0.623	0.286	0.055	0.776
2.50× / 1.25 m	0.620	0.273	0.053	0.777
3.25× / 1.62 m	0.623	0.279	0.049	0.779
4.00× / 2.00 m	0.625	0.279	0.086	0.782

表 4: 同一测试裁块上的类别支持数、原生档预测数与召回。巡航-原生预测翻转 7 次。

类别	标注数	原生档预测数	原生档召回
完好	250	381	0.972
轻微损伤	125	0	0.000
严重损伤	12	0	0.000
损毁	13	19	0.462
巡航 ↔ 原生预测翻转			7




图 6: 有效 GSD 与 macro-F1 / ECE。macro-F1 大致平坦；平均熵随 GSD 变粗**单调上升**——方向与“下降应降低不确定性”的假设一致（未加权版本曾观察到方向相反，见附录变更记录），但幅度很小，仍不足以支撑稳健的跨 GSD 触发决策。

约两倍分离（不下降 0.086，未校准/校准熵约 0.038）：这与温度缩放不改变 $\arg \max$ 相符，说明机制作用在概率而非标签；宏观 F1 平坦不能单独写成“校准无用”。这与第 5.1 节的判断一致：分类器改善方向正确，但当前规模不足以让下降-居中动作产生可辨识的**定类**收益。

超参 $\tau \in \{0.3, 0.4, 0.5, 0.6, 0.7\}$ 只改变下降次数，macro-F1 基本不变，敏感性分析在当前分类器规模下仍缺乏信息量。

5.4 功效分析与事件隔离基准

旧设计 40 题 $\times$ 3 种子、6 策略 Holm 校正下，最小可检测严格 SR 约为 9.6 个百分点（基线 SR=0.05、功效 0.8），远大于 plausible 的 2–5 个百分点效应，故“本次不显著”在设计上接近“永不显著”。功效 0.8 检测 5 个百分点增益约需每策略 444 题。新基准为 200 题，仍欠功效约 2.2 倍，故后文端到端各策略 SR 同质应读作**欠功效下的非结果**，而不是已经证伪了 2–5 个百分点的效应。新 evidence-rich 草稿仅含 test+holdout 事件 (hurricane-michael、palu-tsunami、moore-tornado、nepal-flooding、pinery-bushfire)，

表 5: 平均每样本额外观测 $B = 0.25$ 时的损伤判定 ($n = 400$, 类别加权 checkpoint, $n_{\text{flip}} = 7$)。

策略	macro-F1	精度	ECE
不下降	0.279	0.625	0.086
随机	0.286	0.623	0.074
未校准熵	0.286	0.623	0.037
校准熵	0.286	0.623	0.038
条件期望熵	0.277	0.625	0.050
Conformal	0.286	0.627	0.071
Oracle 上界	0.286	0.623	0.078




图 7: 额外观测预算与损伤宏观 F1。各策略曲线高度重叠; oracle 曲线是逐样本翻转参照而非宏观 F1 上界。

200 题中 easy/medium/hard 为 75/70/55, 含 33 条多地标; 审核字段为“模型辅助审核 + 作者抽查”, 生成脚本对 train/val 事件断言失败。在损伤头召回未恢复前, 扩大题库不能单独挽救 X2。

表 6: 六策略 Holm 校正下的样本量规划。表中 0.0962 是相对基线 SR 的最小可检测差值, 不是成功率本身。

量	取值
基线 SR	0.05
目标绝对增益	0.05
Holm α	0.01
功效 0.8 所需每策略题数	444
旧设计最小可检测 SR	0.0962

5.5 RescueNet 低空评估域

RescueNet 为 Hurricane Michael 无人机影像, 建筑损伤按 FEMA 四级标注, 与 xBD 四类直接映射 [13]; 数据来自 Scientific Data/figshare 的 CC BY 4.0 发布, 仅评估、不训练。该数据集无灾前配对, 双时相输入将灾后裁块复制为灾前通道 (差通道恒为 0, 不是近似为 0)。这一输入构造本身就保证“无变化 $\rightarrow$ 完好”是数学必然, 而不是域漂移的独立证据: 本节结果因此只度量卫星训练分类器在真实低空外观上的漂移, 不能作为“绑定约束在损伤头而非卫星 GSD”的独立支持证据; 后者需要单时相 (仅灾后) 分类头对照, 本文暂未实现, 留作后续工作。FloodNet 因只有淹没/未淹没二值标签且与四级损伤不对齐, 不引入。类别加权 checkpoint 重跑结果与塌缩模式一致: 完好类召回为 1.00, 三类损伤召回均为 0; 精度 0.210、macro-F1 0.087、ECE 0.421 (表7)。

5.6 端到端缺陷与探索回退

对历史全零结果的排查结论如下。

表 7: 卫星训练分类器在 RescueNet 测试影像上的零样本漂移 (灾后裁块复制为灾前)。

项	支持数	指标
图像数	80	–
建筑连通域	181	–
精度	–	0.210
macro-F1	–	0.087
ECE	–	0.421
完好召回	38	1.000
轻微损伤召回	41	0.000
严重损伤召回	22	0.000
损毁召回	80	0.000

1. 旧题库首题起点-目标距离 48.19 m，北向 -20.8 m、东向 43.5 m，不符合 lat/lon 互换的几何签名。
2. E1 与 E11 使用同一 evidence-rich 题库；在复检从未触发时，B1-B3 与六策略轨迹级聚合相同是预期现象，不是串台。
3. LLM/VLM 不可达时，分层规划对无方向先验题每步默认向北， 12×90 m 量级位移与平均 NE 587.6 m 相符。已改为螺旋搜索，单测验证连续四步不再恒为北。
4. **零提议根因（第二处独立缺陷）**：U-Net 定位器推理时把任意输入 resize 到训练尺寸，256 px 机载视场被上采样后建筑尺度偏离训练分布，提议塌缩为 0——同一权重在完整 1024 px 瓦片上产生 95 个提议，在 256 视场上为 0。修复为：对灾前底图整瓦片做一次原生分辨率定位（进程内缓存），再把落进当前视场的框平移到视场坐标；且灾前底图是离线卫星产品，其分辨率与无人机当前高度无关，不再随 GSD 阶梯降质，只有灾后实时观测降质。修复后单题 trace 每步产生 2-10 个建筑提议、损伤分类器全部被调用（此前全程为 0），证据链路首次完整执行。

5. 修复后损伤证据以“完好”为主：分类器对少数“损毁”案例已有一定命中（第5.1节），但“轻微/严重损伤”证据仍几乎不出现，与第5.2节的离线结论闭环——瓶颈不在导航或定位，在损伤头对中间损伤等级的召回。
6. **VLM 恢复与混合指认验证**：视觉语言模型改为进程内 Transformers 直接加载 Qwen2.5-VL-7B（本地权重、离线可复现，不依赖外部推理服务），混合指认路径（检测器优先、VLM 兜底）真实生效。
7. **早停缺陷（第三处独立缺陷）**：两个规划器在目标进入判到达半径（35 m）后原地停止而不平移至目标上方，而成功半径为 25 m，构成系统性早停。修复为判到达后先对准目标再停止。
8. 修复后单题 trace 暴露新的真实误差源：VLM 在起点视场内指认了一处“完全损毁建筑”（视场内 19 m），但对齐 GT 足迹后该位置 61 m 内无损毁建筑，属开放词汇指认误报。这类误报不是实现缺陷，而是需要复检机制去纠偏的对象——但复检又受损伤头塌缩约束，两个失效源在端到端层面耦合。

5.7 Oracle 阶梯与端到端现实检验

在全部修复后的栈上，于事件隔离基准（200 题）重跑：(i) oracle 阶梯 L0–L3（表8），交叉解耦导航与指认；(ii) 主消融 B0–B3 与复检策略族、GPS 定位扰动 ($\sigma \in \{2, 5, 10\}$ m) 及强制退化几何套件（表9）。解释时须注意：在损伤头塌缩的前提下，任何配置的损伤证据与复检触发都受同一上游约束。

L2 是 oracle 初始定位，不是 oracle 导航。 L2 的实现是回合开始即把无人机放到目标正上方，指认模块此后仍照常运行、仍可将其重新拉离目标——导航/运动闭环本身从未被替换或屏蔽。因此 L1–L2 的差值度量的是“指认 vs. 初始位置”，不是“指认 vs. 导航”，下文改称 L2 为“oracle 初始定位”，避免层间归因被误读为对导航模块的检验。真正的 oracle 导航（屏蔽指认对运动的影响）留作后续工作。

瓶颈定位在指认层。 oracle 阶梯给出层间归因：仅替换指认 (L1) 即把严格 SR 从 0.08 提升到 1.00 (NE 0.1 m、SPL 0.986)，说明指认正确时规划-运动闭环几乎无损；而仅替换初始定位 (L2) ——不屏蔽指认——SR 只有 0.50：一半的题在到达后仍被开放词汇误指认重新拉离目标。两者对比表明目标指认是当前剩余瓶颈的主要来源：检测器路径受限于损伤头对中间损伤等级的低召回，VLM 路径则存在 第5.6节所示的开放词汇误报，二者叠加构成 L0 的低 SR。这一结论的边界条件须明确：仿真不含风扰、避障与能耗约束，SR = 1.00 说明“指认正确时该仿真的运动学假设下闭环无损”，不能外推为“导航与运动闭环对真实飞行不再是短板”。

端到端上机制不可辨识，与离线分水岭闭环。 主消融 B0-B2 的 SR 在 0.07-0.08 之间同质，记忆拓扑图 (B3) 反而使 NE 变差 (305.7 m)。五种复检策略 (随机、固定、校准熵、条件期望熵、conformal) SR 完全相同 (0.08)，200 题中触发 0-3 次：损伤证据几乎不存在时，任何触发准则都退化为“从不触发”。这与 第5.3节的离线结论在端到端层面闭环——不是复核机制失败，而是它从未获得可复核的输入。

几何扰动不是当前瓶颈；强制退化几何下 SR 显著更低，但样本量不足以单独立因果论证。 GPS 起点扰动 σ 从 0 增至 10 m，SR 在 0.065-0.095 间非单调波动，量级远小于指认噪声，几何鲁棒性尚未成为可观测约束。强制退化几何 (禁用检测框地理投影与复检居中) 使 SR 降至 0.025、全部回合耗尽 12 步预算、NE 升至 414 m，Fisher 精确检验显示该组 ($k = 5/n = 200$) 与主套件 B2 ($k = 16/n = 200$) SR 差异 $p = 0.023$ (表9 给出各组 95% Wilson 置信区间)。我们只报告该条件下的观测 SR 与显著性检验结果，不把“禁用投影”单一处理下的差异直接推广为“投影通道是到达能力的必要成分”这一更强的因果断言——消融同时改变了投影与复检居中两个环节，无法互相分离。

6 局限与影响

当前绑定约束是损伤分类器在事件不相交测试上对中间损伤等级 (轻微/严重损伤) 召回持续偏低、开放词汇指认存在误报，而不是仿真平台或导

表 8: Oracle 阶梯：导航与指认逐层替换为 oracle 后的到达能力（事件隔离基准， $n = 200$ ）。

层级	设定	n	SR (95% CI)	semSR	NE (m)	SPL
L0	无 oracle (现状)	200	0.080 [0.050,0.126]	0.155	223.9	0.068
L1	oracle 指认	200	1.000 [0.981,1.000]	1.000	0.1	0.986
L2	oracle 初始定位 (指认仍生效)	200	0.500 [0.431,0.569]	0.550	148.5	0.381
L3	oracle 初始定位 + 指认	200	1.000 [0.981,1.000]	1.000	0.0	1.000

表 9: 端到端主消融与扰动套件（事件隔离基准）。SR 附 Wilson 95% 置信区间。固定下降策略触发次数远小于回合数，因为触发仍受上游“存在损伤证据”门控。

套件	配置	n	SR (95% CI)	semSR	NE (m)	复检触发
主套件	B0	200	0.070 [0.042,0.114]	0.165	222.3	0
主套件	B1	200	0.080 [0.050,0.126]	0.155	223.9	0
主套件	B2	200	0.080 [0.050,0.126]	0.155	223.9	0
主套件	B3	200	0.080 [0.050,0.126]	0.140	305.7	0
复检策略族	E11_RANDOM	200	0.080 [0.050,0.126]	0.155	223.9	0
复检策略族	E11_FIXED	200	0.080 [0.050,0.126]	0.155	224.0	3
复检策略族	E11_ENTROPY	200	0.080 [0.050,0.126]	0.155	223.9	1
复检策略族	E11_INFOGAIN	200	0.080 [0.050,0.126]	0.155	223.9	2
复检策略族	E11_CONFORMAL	200	0.080 [0.050,0.126]	0.155	223.9	2
GPS $\sigma=2$ m	B2	200	0.065 [0.038,0.108]	0.140	230.7	1
GPS $\sigma=5$ m	B2	200	0.085 [0.054,0.132]	0.155	221.4	0
GPS $\sigma=10$ m	B2	200	0.095 [0.062,0.144]	0.200	238.6	0
强制退化几何	B2	200	0.025 [0.011,0.057]	0.075	414.4	0

航几何 (oracle 指认下、指认仍生效时到达 $SR = 1.00$, GPS 扰动 $\sigma \leq 10\text{ m}$ 对 SR 无单调影响; 该结论以本仿真的运动学假设——无风扰、无避障、无能耗约束——为前提, 不外推到真实飞行)。类别加权训练把训练集 macro-F1 提升到 0.49–0.57, 证明分类器有能力学到损伤线索, 但同等条件下验证/测试 macro-F1 仅到 0.22–0.28, 是真实的事件级泛化缺口, 不是训练配方完全未处理不平衡的产物。与标准 (非事件不相交) 切分对照显示: 换用文献常见的更宽松协议后 macro-F1 仅升至 0.31, 离公开基线的 ~ 0.7 仍有明显差距, 这部分差距应归因于本文使用的轻量架构 (ResNet18 双塔、8 epoch、无集成) 与训练规模, 更强的骨干网络、更长训练与专门的类别不平衡技巧 (focal loss、两阶段训练、过采样) 留作后续工作。分辨率阶梯会改变高频像素, 降质后平均熵方向已与假设一致 (随 GSD 变粗上升), 但幅度仍小, 不足以支撑稳健的跨 GSD 触发决策。该阶梯是在单一原生分辨率上撤销合成模糊, 零结果只说明机制在该构造上不可识别, 不能外推为真实低空厘米级观测无信息。RescueNet 提供真实低空端点, 但没有与 xBD 瓦片的逐栋地理配准, 且缺乏灾前配对 (差通道恒为 0), 该结果只能作为域外可用性检查, 不能单独支持“绑定约束在损伤头”的因果论证。语言条件搜索的指令空间仍偏模板化, 尽管已加入方位、否定与多地标; 在语言复杂度不足时不应自称完整 VLN。旧 40×3 设计统计功效不足; 新基准规模按功效分析扩大, 但仍需损伤证据阳性回合才能比较复检策略。仿真不包含风扰、斜视、运动模糊、通信与电池。DisasterClaw 定位为决策支持, 损伤结论应保留人工确认。地理影像可能暴露敏感位置, 轨迹发布需按灾种做隐私审查。

7 结论

本文给出一套面向灾后侦察的语言条件智能体与地理配准仿真/监控平台, 并将航空应急侦察中的“再看一眼”写成预算受限的主动重观测, 用有效 GSD 把下降变成可测物理量。系统贡献是工程存在性声明, 不改变下述科学结论。离线分配实验的初步结果是负结果: 损伤分类器预测几乎不随 GSD 翻转, 校准策略、共形触发与 oracle 参照因此难以在宏观 F1 上区分。我们没有直接把这个负结果当作结论, 而是补做了三组反事实排除实

验：训练曲线核查（排除“从未训练成功”）、类别加权重训（排除“完全未处理类别不平衡”，且确有部分改善——事件不相交测试上“损毁”类召回从 0.007 恢复到 0.16），标准切分基线对标（把“评测协议过严”与“架构规模不足”分离，显示后者是差距的主要来源）。三组实验一致指向同一个更精确的结论：**分类器有能力在训练分布内学到损伤线索，但对事件级域偏移与中间损伤等级的泛化能力不足**，这是一个真实的、有训练/验证曲线支撑的瓶颈，而不是未经检验的失败归因。感知校准半题（温度缩放降低域内 ECE、argmax 不变）仍然成立，但不能单独支撑决策主张。端到端语言条件搜索不再承担唯一验证出口；历史全零成功的三处相互独立实现缺陷（LLM 不可达时探索恒向北、机载视场下定位器零提议、判到达后不对准目标的系统性早停）已全部修复并以单题 trace 与 oracle 阶梯验证，此处作为可复现性说明而非独立贡献。修复后的 oracle 阶梯把剩余瓶颈压在目标指认层：oracle 指认使严格 SR 从 0.08 达到 1.00 (SPL 0.986)，oracle 初始定位（指认仍生效）仅得 0.50；在本仿真无风扰/无避障/无能耗约束的运动学假设下，指认正确时闭环几乎无损，但这一结论不外推到真实飞行。事件不相交协议、功效分析、类别加权训练与标准切分对标是为了让后续正结果站得住。下一步应尝试更强的类别不平衡技巧（focal loss、两阶段训练、过采样）与更大骨干网络，再重跑 X2；在那之前不应把机制写成已验证的任务增益，也不应把智能体栈的可运行性误读为任务已成功。

参考文献

- [1] Peter Anderson, Qi Wu, Damien Teney, Jake Bruce, Mark Johnson, Niko Sünderhauf, Ian Reid, Stephen Gould, and Anton van den Hengel. Vision-and-language navigation: Interpreting visually-grounded navigation instructions in real environments. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 3674–3683, 2018.
- [2] Ruzena Bajcsy. Active perception. *Proceedings of the IEEE*, 76(8):996–1005, 1988.

- [3] Wele Gedara Chaminda Bandara and Vishal M. Patel. A transformer-based siamese network for change detection. In *IEEE International Geoscience and Remote Sensing Symposium*, pages 207–210, 2022.
- [4] Andreas Bircher, Mina Kamel, Kostas Alexis, Helen Oleynikova, and Roland Siegwart. Receding horizon “next-best-view” planner for 3d exploration. In *IEEE International Conference on Robotics and Automation*, pages 1462–1468, 2016.
- [5] Hao Chen, Zipeng Qi, and Zhenwei Shi. Remote sensing image change detection with transformers. *IEEE Transactions on Geoscience and Remote Sensing*, 60:1–14, 2022.
- [6] Sheng Fang, Kaiyu Li, Jinyuan Shao, and Zhe Li. SNUNet-CD: A densely connected siamese network for change detection of VHR images. *IEEE Geoscience and Remote Sensing Letters*, 19:1–5, 2022.
- [7] Yunpeng Gao, Zhigang Wang, Pengfei Han, Linglin Jing, Dong Wang, and Bin Zhao. Exploring spatial representation to enhance LLM reasoning in aerial vision-language navigation. *arXiv preprint arXiv:2410.08500*, 2024.
- [8] Chuan Guo, Geoff Pleiss, Yu Sun, and Kilian Q. Weinberger. On calibration of modern neural networks. In *Proceedings of the 34th International Conference on Machine Learning*, pages 1321–1330, 2017.
- [9] Ritwik Gupta, Richard Hosfelt, Sandra Sajeed, Nirav Patel, Bryce Goodman, Jigar Doshi, Eric Heim, Howie Choset, and Matthew Gaston. xBD: A dataset for assessing building damage. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, 2019.
- [10] Jungdae Lee, Taiki Miyanishi, Shuhei Kurita, Koya Sakamoto, Daichi Azuma, Yutaka Matsuo, and Nakamasa Inoue. CityNav: A large-scale dataset for real-world aerial navigation. In *Proceedings of the*

- IEEE/CVF International Conference on Computer Vision*, pages 5912–5922, 2025.
- [11] Shubo Liu, Hongsheng Zhang, Yuankai Qi, Peng Wang, Yanning Zhang, and Qi Wu. AerialVLN: Vision-and-language navigation for UAVs. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 15384–15394, 2023.
- [12] Yaniv Ovadia, Emily Fertig, Jie Ren, Zachary Nado, D. Sculley, Sebastian Nowozin, Joshua Dillon, Balaji Lakshminarayanan, and Jasper Snoek. Can you trust your model’s uncertainty? Evaluating predictive uncertainty under dataset shift. In *Advances in Neural Information Processing Systems*, volume 32, 2019.
- [13] Maryam Rahnemoonfar, Tashnim Chowdhury, and Robin Murphy. RescueNet: A high resolution UAV semantic segmentation dataset for natural disaster damage assessment. *Scientific Data*, 10:913, 2023.
- [14] Allen Z. Ren, Anushri Dixit, Alexandra Bodrova, Sumeet Singh, Stephen Tu, Noah Brown, Peng Xu, Leila Takayama, Fei Xia, Jack Varley, Zhenjia Xu, Dorsa Sadigh, Andy Zeng, and Anirudha Majumdar. Robots that ask for help: Uncertainty alignment for large language model planners. In *Conference on Robot Learning*, 2023.
- [15] Dhruv Shah, Blazej Osinski, and Sergey Levine. LM-Nav: Robotic navigation with large pre-trained models of language, vision, and action. In *Proceedings of The 6th Conference on Robot Learning*, volume 205 of *Proceedings of Machine Learning Research*, pages 492–504. PMLR, 2023.
- [16] Weichen Zhang, Chen Gao, Shiquan Yu, Ruiying Peng, Baining Zhao, Qian Zhang, Jinqiang Cui, Xinlei Chen, and Yong Li. CityNavAgent: Aerial vision-and-language navigation with hierarchical semantic planning and global memory. In *Proceedings of the 63rd Annual Meeting*

of the Association for Computational Linguistics (Volume 1: Long Papers), pages 31292–31309, Vienna, Austria, 2025. Association for Computational Linguistics.

A 附录：协议、切分与复现

事件切分。 训练: guatemala-volcano, hurricane-florence, hurricane-matthew, joplin-tornado, lower-puna-volcano, midwest-flooding, portugal-wildfire, santa-rosa-wildfire, socal-fire, sunda-tsunami, tuscaloosa-tornado, woolsey-fire。验证 (温度拟合): hurricane-harvey, mexico-earthquake。测试: hurricane-michael, palu-tsunami。留出: nepal-flooding, moore-tornado, pinery-bushfire。

预注册假设 (保持)。 H1: 温度缩放降低事件不相交测试 ECE 且不改变精度。H2: 差分注意力相对拼接的均匀精度/校准优势。H3–H4: 信息增益或共形触发相对无/随机/固定下降的判断增益。零触发回合对条件 ΔU 视为缺失, 触发率报 0, 不得填补成功下降。

H2 结果。 差分注意力与拼接融合在事件不相交切分下的验证/测试 macro-F1 互有胜负 (表1): 拼接在验证集选择指标上略高, 差分注意力在测试集“损毁”召回上更高。按预注册规则, H2 判定为“在当前样本量下无法区分”, 两种融合方式均不获得“均匀优势”结论。

损伤分类器训练修复。 复核发现早期版本训练日志汇报的验证集 accuracy (≈ 0.80) 具有误导性: 在完好类占比 66%–79% 的数据上, 未加权交叉熵 + 按 accuracy 选 checkpoint 会系统性收敛到常数预测器, 训练集自身 macro-F1 当时也只有 ≈ 0.22 – 0.25 (三类损伤召回接近 0), 说明问题出在训练配方而非某次评测脚本的 bug。修复: (i) 类别加权交叉熵 (训练集逐类频率倒数); (ii) 模型选择改为验证集 macro-F1; (iii) 训练收尾对 reload 后的 checkpoint 现场核验, 数值与训练期间记录不一致则拒绝保存 (见 backend/change_perception.py 的 macro_f1_from_logits / class_weights_from_records)。另需记录一次排查过程中的假警报: 复核者最初误用一份早期废弃的、非事件不相交的小规模数据目录(xbd_change/)

复算验证集表现，得到与训练日志严重不符的数字，一度怀疑存在 checkpoint 保存/加载 bug；改用训练时真正使用的事件不相交目录(xbd_change_strict_v1/，与本节“事件切分”一致)后，reload 数值与训练日志完全吻合，排除了保存/加载环节的 bug，问题精确定位到训练配方本身。如实记录该假警报是为了让复现者不必重复同一轮排查。

标准（非事件不相交）切分基线。 使用 gen_xbd_change_dataset.py 的 legacy_tile_random 模式(--strict-event-split 关闭)生成 xbd_change_standard_v1/: train/tier3 内按图块 95/5 随机切分为 train/val，官方 test 目录作为 test，holdout 灾害事件仍整体排除。该协议与公开 xBD/xView2 基线一致（同一灾害事件的图像可同时出现在 train 与 test，只是不同图块）。

权重溯源 (SHA-256 前 16 位)。 U-Net 定位器 resnet34_strict_v1.pt: 4802e3886249deee; 双时相损伤分类器 (当前部署, 事件不相交 + 类别加权 + 差分注意力)strict_diff_attention_seed0_v2.pt: 54df321fad18f054; H2 对照 (事件不相交 + 类别加权 + 拼接)strict_baseline_seed0_v2.pt: a4f38095e4cf6141; 协议对照 (标准切分 + 类别加权 + 拼接)standard_baseline_seed0.pt: 3355700071b30f37; YOLO 对照 best.pt: dcd11c194c5bf44b。早期未加权版本 strict_diff_attention_seed0.pt (724c30fadd480b43) 保留在仓库中作为对照，不再用于正文结果。每次评测的 results.json 内嵌完整哈希、字节数与环境快照。

复现入口。 数据根目录由环境变量 XBD_CHANGE_ROOT (事件不相交切分) 与 XBD_CHANGE_STANDARD_ROOT (官方标准切分) 给出，不在正文写绝对路径。

```
# 重训损伤分类器 (类别加权 + 宏观 F1 选择 + 事件不相交断言)
python backend/change_perception.py train \
  --data-dir "$XBD_CHANGE_ROOT" --require-event-disjoint \
  --epochs 8 --class-weighted --diff-attention \
  --out backend/outputs/change_perception/strict_diff_attention_seed0_v2.pt
```

训练/验证/测试三切分宏观 F1、逐类召回、训练曲线

```
python scripts/benchmarks/eval_change_perception_v2.py \  
    --out runs/benchmarks/paper_cja_v2/change_perception_v2_report.json
```

全量实验

```
bash scripts/benchmarks/run_cja_experiments.sh
```

权重路径相对于仓库:backend/outputs/...。本地视觉语言模型:设 VLM_PROVIDER=qwen_vl_1.7 与 BASE_MODEL=Qwen/Qwen2.5-VL-7B-Instruct, 由 Transformers 进程内直接加载本地权重 (约 16 GB, bfloat16 推理约需 20 GB 显存), 无需任何外部推理服务。投稿前将本中文 LaTeX 按《航空学报》Word 模板转写; 表图由 paper_cja/generated 导出。控制台截图放入 paper_cja/figures/, 步骤见 paper_cja/SCREENSHOTS.md。